

Chapitre 2

Statistiques

2.1 Rappels en statistiques univariées

Définition 2.1.1 Population et caractère

Soit Ω un ensemble.



- Ω désigne la population qui fera l'objet de l'étude.
- Les éléments $\omega_i \in \Omega$ sont les individus.
- Une variable statistique (ou caractère) X sur la population Ω est une application $X : \Omega \rightarrow F$. Dans le cas où F est une partie de $\mathbb{R}$, on dit que le caractère est quantitatif. Sinon, on dit que le caractère est qualitatif.

Remarque



Dans la suite, on ne considère que les caractères quantitatifs.

Définition 2.1.2 Échantillon



- Si Ω est un ensemble fini, le nombre d'éléments de Ω , noté $\text{Card}(\Omega)$, est l'effectif de la population.
- Quand il n'est pas possible d'étudier chaque individu de la population, on étudie seulement les individus d'une partie finie E de la population Ω . Dans ce cas, la partie E est appelée échantillon. Le nombre d'individus de l'échantillon, $\text{Card}(E)$, est la taille de l'échantillon.
- Ainsi, si N désigne la taille, on peut écrire $E = \{e_1, e_2, \dots, e_N\}$ où les e_i sont distincts deux à deux.

Définition 2.1.3 Variables statistiques

On distinguera deux types de variables statistiques :



- Si l'ensemble des valeurs prises par la variable, noté $X(\Omega)$, est un ensemble fini, on dit que la variable quantitative est discrète.
- Dans le cas contraire, on dit que la variable quantitative est continue.

2.1.1 Cas discret**Définition 2.1.4 Série statistique**

Soit X une variable statistique discrète et $E = \{e_1, e_2, \dots, e_N\}$ un échantillon. La donnée du N -uplet des observations



$$x = (X(e_1), X(e_2), \dots, X(e_N))$$

définit une série statistique.

Définition 2.1.5 Modalités, effectif, fréquences

- L'échantillon étant un ensemble fini, l'ensemble des valeurs prises par la variable X sur E est aussi fini. On peut l'écrire $X(E) = \{m_1, m_2, \dots, m_p\}$ où $m_1 < m_2 < \dots < m_p$ où chaque m_i est une valeur ou modalité.
- L'effectif d'une modalité m_i est le nombre d'individus de E pour lequel le caractère prend la modalité m_i . C'est-à-dire

$$n_i = \text{Card}\{e \in E \mid X(e) = m_i\}.$$



Si N est la taille de l'échantillon, $N = \sum_{i=1}^p n_i$.

- La fréquence d'une modalité m_i est la quantité

$$f_i = \frac{\text{Effectif de la modalité}}{\text{Taille de l'échantillon}} = \frac{n_i}{N}.$$

On a alors $\sum_{i=1}^p f_i = 1$.

- La fréquence cumulée d'une modalité m_i est la somme de toutes les fréquences des modalités qui lui sont inférieures. Autrement dit,

$$F_i = \sum_{j \leq m_i} f_j.$$

Définition 2.1.6 Tableau de série statistique

Donner une série statistique est équivalent à la donnée du couple (m, n) où

- $m = (m_1, m_2, \dots, m_p)$ est le p -uplet constitué des modalités,
- $n = (n_1, n_2, \dots, n_p)$ est le p -uplet constitué des effectifs.



Il est alors commode de représenter une série statistique à l'aide d'un tableau :

Modalités	m_1	m_2	$\dots$	m_p	Total
Effectifs	n_1	n_2	$\dots$	n_p	N

Exemple**Notes d'Inès**

Voici les notes d'Inès cette année en mathématiques :

$$x = (15, 12, 8, 14, 12, 15, 10, 12, 10, 12, 15, 15).$$

Série que l'on résume sous la forme :

Modalités	8	10	12	14	15	Total
Effectifs	1	2	4	1	4	12

QCM

- Une série statistique discrète est définie par :
 - une fonction de densité
 - une liste ordonnée de classes
 - un N -uplet d'observations
 - une fonction de répartition
- L'effectif total N d'une série statistique discrète est :
 - le nombre de modalités
 - la somme des fréquences
 - la somme des effectifs
 - le nombre de classes
- La fréquence cumulée F_i associée à la modalité m_i est :
 - égale à n_i
 - égale à $\sum_{j=i}^p f_j$
 - égale à $\sum_{j \leq i} f_j$
 - toujours égale à 1

2.1.2 Cas continu**Méthode Regroupement en classes**

On découpe l'ensemble des valeurs possibles $X(\Omega)$ en un certain nombre d'intervalles. Notons $p \in \mathbb{N}^*$ le nombre d'intervalles choisis. Ces intervalles doivent être deux à deux disjoints, et leur réunion est égale à (ou contient) l'ensemble des valeurs possibles.

Plus précisément, en notant $a_1, a_2, \dots, a_{p+1} \in \mathbb{R}$, les bornes de tous ces intervalles avec $a_1 < a_2 < \dots < a_{p+1}$, on a $X(\Omega) \subset \bigcup_{i=1}^p [a_i; a_{i+1}[$.

Définition 2.1.7 Classe

L'intervalle $[a_i; a_{i+1}[$ est une classe.

Remarque

- On peut ainsi définir l'effectif d'une classe et sa fréquence.
- On peut utiliser ces définitions pour une variable discrète lorsque l'ensemble des valeurs prises est trop important. Par exemple, pour étudier le nombre d'habitants par département, on pourra faire des tranches de 200 000 habitants.

QCM

1. Dans le cas continu, les valeurs de la variable sont :
 - (a) nécessairement finies
 - (b) regroupées en classes
 - (c) toutes observables exactement
 - (d) toujours discrètes
2. Une classe statistique est :
 - (a) une modalité
 - (b) un intervalle de valeurs
 - (c) un effectif
 - (d) une fréquence cumulée
3. Le regroupement en classes permet :
 - (a) de transformer une variable continue en discrète
 - (b) de calculer exactement la moyenne
 - (c) d'éviter toute perte d'information
 - (d) d'ordonner les individus

2.1.3 Paramètres

La collecte massive de données permise par la révolution numérique de ces dernières années a rendu l'emploi des statistiques de plus en plus nécessaire. Comme le souligne R.A Fisher, un des objectifs des statistiques est d'introduire des quantités pertinentes pour l'analyse des données afin d'en extraire les informations pertinentes. Les plus élémentaires étant la moyenne, la variance, l'écart-type...

Paramètres de position

Définition 2.1.8 Mode



Un mode d'une série statistique est une modalité pour laquelle l'effectif est maximal.

Remarque



Un mode n'est pas nécessairement unique.

Exemple

Il y a deux modes dans la série des notes d'Inès : 12 et 15 d'effectif 4.

Définition 2.1.9 Moyenne empirique

Soit $x = (x_i)_{1 \leq i \leq N}$, une série statistique. On définit la moyenne de la série par



$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i.$$

Si $(m_i)_{1 \leq i \leq p}$, $(n_i)_{1 \leq i \leq p}$ et $(f_i)_{1 \leq i \leq p}$ désignent respectivement les modalités, les effectifs et les fréquences, on a aussi

$$\bar{x} = \frac{1}{N} \sum_{i=1}^p n_i m_i = \sum_{i=1}^p f_i m_i.$$

Exemple

Calcul de moyenne

- On a directement $\bar{x} = \frac{1}{12}(1 \times 8 + 2 \times 10 + 4 \times 12 + 1 \times 14 + 4 \times 15) = 12,5$.
- Avec Python, la moyenne est obtenue par la commande `mean()` qui prend en argument une liste.

```
import numpy as np
np.mean(L)
```

Remarque Phénomène de Will Rogers

¶ Quand, pendant la Grande Dépression, les ouvriers pauvres ont quitté l'Oklahoma pour la Californie, le niveau intellectuel moyen des deux États a augmenté. Cette citation est attribuée au comédien américain originaire d'Oklahoma : Will Rogers.

C'est une façon déguisée de dire que les habitants de Californie sont en moyenne plus bêtes que ceux de l'Oklahoma. Le quotient intellectuel de la Californie augmente car il accueille des Oklahomans plus intelligents alors que celui de l'Oklahoma augmente car les émigrés faisaient baisser la moyenne.

Définition 2.1.10 La médiane d'une série statistique

Soit $x = (x_i)_{1 \dots N}$ une série statistique ordonnée suivant l'ordre croissant. On définit la médiane de la série statistique par



$$m_e = \begin{cases} x_p & \text{si } N \text{ est impair avec } p = \frac{N+1}{2}, \\ \frac{x_p + x_{p+1}}{2} & \text{si } N \text{ est pair avec } p = \frac{N}{2}. \end{cases}$$

Autrement dit, la médiane est un nombre réel m_e tel que le nombre d'individus pour lesquels X prend une valeur inférieure ou égale à m_e soit égal au nombre d'individus pour lesquels X prend une valeur supérieure ou égale à m_e .

Exemple**Calcul de médiane**

— Ordonnons les douze notes d'Inès :

$$x = (15, 12, 8, 14, 12, 15, 10, 12, 10, 12, 15, 15), \quad \tilde{x} = (8, 10, 10, 12, 12, 12, 12, 14, 15, 15, 15, 15).$$

La médiane est donnée par

$$m_e = \frac{\tilde{x}_6 + \tilde{x}_7}{2} = 12.$$

— Avec Python, la médiane est obtenue par la commande `median()` :

```
>>> import numpy as np
>>> np.median(L)
```

— Selon l'INSEE, le salaire mensuel moyen (équivalent temps plein en 2019) d'un Français est de 2 424 euros net. Le salaire médian, lui, s'élève à 1 940 euros par mois. La moyenne est relevée par les très hauts revenus qui ne concernent qu'une minorité de salariés. Ce dernier exemple illustre un fait important : **la moyenne est sensible aux valeurs extrêmes alors que la médiane ne l'est pas.**

■ Exercice 2.1 Transformation affine d'une série statistique

Soient a, b deux réels et x une série statistique. Exprimer en fonction de la moyenne de x , la moyenne de la série $x' = ax + b$. Faire de même avec la médiane.

Remarque



La série $x' = ax + b$ est la série obtenue à partir de x en remplaçant chaque donnée x_i par le réel $ax_i + b$.

Définition 2.1.11 *Quartiles*

Soit x une série statistique.



- Le premier quartile de x est la plus petite modalité de la série pour laquelle la fréquence cumulée est supérieure ou égale à $\frac{1}{4}$.
- Le troisième quartile de x est la plus petite modalité de la série pour laquelle la fréquence cumulée est supérieure ou égale à $\frac{3}{4}$.

Remarque



De même, on définit le k -ième décile comme la plus petite modalité de la série pour laquelle la fréquence cumulée est supérieure ou égale à $\frac{k}{10}$.

Exemple**Répartition du patrimoine**

Ci-dessous, la répartition du patrimoine net des Français en 2018 suivant les déciles (source I.N.S.E.E). Par exemple, 10% des Français ont un patrimoine net supérieur à 549 600 euros.

- 1er décile : 2600
- 2e décile : 9000
- 3e décile : 23400
- 4e décile : 60800
- 5e décile : 117000
- 6e décile : 176700
- 7e décile : 246200
- 8e décile : 348700
- 9e décile : 549600
- 95e centile : 794800
- 99e centile : 1745800

2.2 Paramètres de dispersion**Définition 2.2.1 La variance empirique et l'écart-type**

Soit x une série statistique.

- La variance de la série est le réel, noté $\sigma(x)^2$, défini par



$$\sigma(x)^2 = \frac{1}{N} \left((x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_N - \bar{x})^2 \right) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2.$$

- L'écart-type, $\sigma(x)$ d'une série statistique est défini comme la racine carrée de la variance.

Remarque

- Si les modes $m_1, m_2, \dots, m_p$ de la série sont donnés avec leurs effectifs $n_1, n_2, \dots, n_p$ ou leurs fréquences $f_1, f_2, \dots, f_p$, alors



$$\sigma(x)^2 = \frac{1}{N} \sum_{i=1}^p n_i (m_i - \bar{x})^2 = \sum_{i=1}^p f_i (m_i - \bar{x})^2.$$

- Une variance est toujours un nombre positif. L'écart-type est donc bien défini.
 — Une série a une variance nulle si et seulement si toutes les valeurs de la série sont identiques.

Exemple**Calcul de variance**

- Pour les notes d'Inès :

$$\begin{aligned} \sigma(x)^2 = \frac{1}{12} & \left(1 \times (8 - 12.5)^2 \right. \\ & + 2 \times (10 - 12.5)^2 \\ & + 4 \times (12 - 12.5)^2 \\ & + 1 \times (14 - 12.5)^2 \\ & \left. + 4 \times (15 - 12.5)^2 \right) \approx 5.08 \end{aligned}$$

puis un écart-type de 2.25.

- Avec Python, la variance et l'écart-type sont obtenus par les commandes `var()` et `std()`.

Proposition 2.2.2 Transformation affine

Soit x une série statistique et $a, b \in \mathbb{R}$. Si x' est la série statistique obtenue en modifiant chaque donnée x_i en $ax_i + b$, alors



$$V' = a^2 V \quad \text{et} \quad \sigma' = |a| \sigma$$

où V, σ (resp. V', σ') désignent la variance et l'écart-type de x (resp. de x').

■ **Exercice 2.2** **Démonstration de la proposition**

Prouver la proposition précédente.

Théorème 2.2.3 Formule de Koenig-Huygens

Soit x une série statistique de modalités $(m_i)_{1 \dots p}$, d'effectifs $(n_i)_{1 \dots p}$ et de variance $\sigma(x)^2$, alors

$$\sigma(x)^2 = \left(\frac{1}{N} \sum_{i=1}^N x_i^2 \right) - \bar{x}^2 = \left(\frac{1}{N} \sum_{i=1}^p n_i m_i^2 \right) - \bar{x}^2.$$

■ Exercice 2.3 **Formule de Koenig-Huygens**

Prouver ce théorème.

Remarque

Si x^2 désigne la série dont chaque donnée est x_i^2 . On démontre que $\frac{1}{N} \sum_{i=1}^p n_i m_i^2$ est la moyenne $\overline{(x^2)}$. La formule de Koenig-Huygens devient alors

$$\sigma(x)^2 = \overline{(x^2)} - (\bar{x})^2.$$

■ Exercice 2.4 **L'écart-type, un indicateur de dispersion**

Soit $x = (x_i)_{1 \dots N}$ une série statistique avec $\bar{x}$ et $\sigma(x)$, respectivement la moyenne et l'écart-type de la série. Soit r le nombre d'éléments de la série statistique compris entre $\bar{x} - 2\sigma(x)$ et $\bar{x} + 2\sigma(x)$.

1. Montrer que

$$\sum_{k=1}^N (x_k - \bar{x})^2 \geq 4\sigma(x)^2(N - r).$$

2. En déduire qu'au moins les trois quarts des éléments de la série statistique sont compris entre $\bar{x} - 2\sigma(x)$ et $\bar{x} + 2\sigma(x)$.

QCM

1. Le mode d'une série statistique est :

- (a) la valeur moyenne
- (b) la valeur centrale
- (c) la valeur la plus fréquente
- (d) toujours unique

2. La moyenne empirique d'une série est :
 - (a) toujours une modalité
 - (b) sensible aux valeurs extrêmes
 - (c) égale à la médiane
 - (d) insensible aux transformations affines
3. La médiane d'une série statistique :
 - (a) dépend fortement des valeurs extrêmes
 - (b) est toujours égale à la moyenne
 - (c) partage la série en deux groupes de même effectif
 - (d) est définie uniquement si N est impair

2.2.1 Histogrammes

Un histogramme donne une idée graphique de la répartition des valeurs du caractère sur l'échantillon. Ce graphique est obtenu en traçant, pour chaque $i \in [[1, p]]$, le rectangle de base $[a_i, a_{i+1}]$ sur l'axe des abscisses et en ordonnées, l'effectif de la classe $[a_i, a_{i+1}]$.

Méthode *Création d'un histogramme avec Python*

```
inter = np.linspace(0, 2.810*6, 15)
plt.hist(L, bins=inter)
plt.xlabel('Nbre habitants (en millions)')
plt.ylabel('Nbre de départements')
plt.show()
```

QCM

1. Dans un histogramme, l'aire d'un rectangle est proportionnelle :
 - (a) à la modalité
 - (b) à l'effectif de la classe
 - (c) à la moyenne
 - (d) à la variance
2. Les rectangles d'un histogramme :
 - (a) sont toujours disjoints
 - (b) ont tous la même hauteur
 - (c) peuvent avoir des largeurs différentes
 - (d) représentent des fréquences cumulées
3. Un histogramme est particulièrement adapté :
 - (a) aux séries qualitatives
 - (b) aux séries discrètes à peu de modalités
 - (c) aux séries continues
 - (d) aux séries à deux variables

2.3 Statistiques bivariées

Dans la suite, x, y désigne deux séries statistiques. La question est de savoir dans quelle mesure l'une des deux, dite expliquée, dépend de l'autre, dite explicative.

2.3.1 Premières définitions

Définition 2.3.1 Covariance empirique



Soient $x = (x_i)_{1 \dots N}$ et $y = (y_i)_{1 \dots N}$, deux séries statistiques. On définit la covariance des deux séries par :

$$\text{Cov}(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}).$$

Définition 2.3.2 Coefficient de corrélation linéaire empirique



Si les séries x et y ne sont pas constantes, on définit aussi le coefficient de corrélation linéaire empirique par :

$$\rho(x, y) = \frac{\text{Cov}(x, y)}{\sigma(x)\sigma(y)}.$$

Remarque



- $\rho(x, y)$ est un réel de $[-1, 1]$.
- On a l'égalité $\rho(x, y) = \pm 1$ si et seulement s'il existe a et b tels que pour tout indice i , $y_i = ax_i + b$. Dans ce cas, le signe de a est le même que celui de $\rho(x, y)$.

■ Exercice 2.5 Propriétés du coefficient de corrélation

Prouver les deux remarques précédentes.

Proposition 2.3.3 Calcul de la covariance

Soient $x = (x_i)_{1 \leq i \leq N}$ et $y = (y_i)_{1 \leq i \leq N}$, deux séries statistiques. On a :



$$\text{Cov}(x, y) = \overline{(x \cdot y)} - \bar{x} \cdot \bar{y}$$

où $\overline{(x \cdot y)}$ désigne la moyenne de la série $x \cdot y = (x_i \cdot y_i)_{1 \leq i \leq N}$.

Remarque

La corrélation n'est pas causalité.

QCM

1. La covariance empirique mesure :
 - (a) la dispersion d'une seule variable
 - (b) le lien linéaire entre deux séries
 - (c) une relation causale
 - (d) une distance entre deux points
2. Si $\text{Cov}(x, y) = 0$, alors :
 - (a) x et y sont indépendantes
 - (b) il n'existe aucun lien entre x et y
 - (c) il n'y a pas de lien linéaire
 - (d) les moyennes sont nulles
3. Le coefficient de corrélation linéaire $\rho(x, y)$:
 - (a) peut dépasser 1
 - (b) est toujours positif
 - (c) est compris entre -1 et 1
 - (d) mesure une relation causale

2.4 Nuage de points**Définition 2.4.1 Nuage de points**

Soient $x = (x_i)_{1 \leq i \leq N}$ et $y = (y_i)_{1 \leq i \leq N}$, deux séries statistiques. Le nuage de points associé à ces deux séries est l'ensemble des points M_i du plan de coordonnées (x_i, y_i) où $i \in [[1, N]]$.

**Remarque**

Le point $(\bar{x}, \bar{y})$ est le point moyen du nuage.

Méthode *Tracé d'un nuage de points avec Python*

```
import matplotlib.pyplot as plt
import numpy as np

# Exemples avec deux séries
x = np.array([1, 3, 4, 5, 8, 11, 13])
y = np.array([28.1, 27.5, 30.3, 31.8, 37.6, 39, 40.6])

# Tracé du nuage de points et du point moyen
plt.plot(x, y, 'r*')
plt.plot(np.mean(x), np.mean(y), 'ko')
```

Proposition 2.4.2 *Problème des moindres carrés et droite de régression*

Soit n un entier supérieur à 2. Considérons n points de $\mathbb{R}^2$, $(x_1, y_1), \dots, (x_n, y_n)$ non alignés verticalement. On cherche la droite qui $\acute{a}$ au mieux ces n points. Si on note $y = ax + b$, l'équation d'une droite, on cherche à minimiser l'erreur

$$E_r = \sum_{i=1}^n d_i^2 = \sum_{i=1}^n (ax_i + b - y_i)^2.$$



Si on introduit les variances et covariances empiriques, on obtient

$$a = \rho(x, y) \frac{\sigma(y)}{\sigma(x)} = \frac{\text{Cov}(x, y)}{V(x)} \quad \text{et} \quad b = \bar{y} - a\bar{x}.$$

L'équation de la droite est alors :

$$y - \bar{y} = \rho(x, y) \frac{\sigma(y)}{\sigma(x)} (x - \bar{x}).$$

**Remarque**

Avec cette dernière expression, on constate que le point moyen appartient à la droite de régression.

Remarque

Un des inconvénients de la droite de régression est qu'elle est très sensible aux valeurs extrêmes : une seule valeur très éloignée de la droite modifie beaucoup le coefficient de corrélation linéaire et donc la pente de la droite. En particulier, la droite est très sensible aux erreurs de mesure.

■ Exercice 2.6 Droite de régression par les fonctions de plusieurs variables

Soient x, y deux séries statistiques avec $\sigma(x) \neq 0$. Soit f la fonction définie sur $\mathbb{R}^2$ par :

$$\forall (a, b) \in \mathbb{R}^2, \quad f(a, b) = \sum_{k=1}^n (ax_k + b - y_k)^2$$

1. Justifier que f est de classe C^2 sur $\mathbb{R}^2$.
2. (a) Écrire le système d'équations S permettant de déterminer les points critiques de f .
 (b) Résoudre le système S . En déduire que f admet un unique point critique $(\hat{a}, \hat{b})$ que l'on exprimera en fonction de $\bar{x}, \bar{y}, \sigma(x)$ et $\text{Cov}(x, y)$.
 (c) Montrer que ce point critique correspond à un minimum local de f .
 (d) Établir la formule suivante :

$$f(\hat{a}, \hat{b}) = n\sigma(y)^2(1 - \rho(x, y)^2)$$

3. (a) Montrer que l'on a : $|\rho(x, y)| \leq 1$.
 (b) Que peut-on dire du nuage de points lorsque $|\rho(x, y)| = 1$?

Remarque

Retenons que lorsque le coefficient de corrélation linéaire est proche de ± 1 , la droite de régression approche bien le nuage de points. Dans ce cas, on peut modéliser la dépendance et faire des prédictions. De plus, si le coefficient de corrélation est positif, les données x_i n'auront tendance à augmenter lorsque y_i augmente et inversement si le coefficient est négatif.

2.5 Exercices

■ Exercice 2.7 Quelques biais statistiques

Chercher l'erreur ou le biais dans les raisonnements suivants :

1. Dans la classe d'ECG, on compte qu'en moyenne les élèves ont 1.7 frères et surs. Ce qui donne 2.7 enfants par femme alors que le nombre d'enfants par femme n'est que de 1.8 dans la population française. Donc les enfants de familles nombreuses font plus facilement des études.
2. L'espérance de vie des professeurs de mathématiques est de 82 ans, soit 3 ans de plus que l'espérance de la population française. Donc les mathématiques sont bonnes pour la santé !
3. Lors de la Seconde Guerre Mondiale, la Royal Air Force souhaite améliorer le taux de retour de ses bombardiers partis frapper les positions allemandes. Les ingénieurs de la R.A.F. décident d'étudier la localisation des impacts de balles sur les avions à leur retour de mission, puis de renforcer le blindage sur les zones les plus atteintes.
4. En 1936, le démocrate Franklin D. Roosevelt et le républicain Alfred M. Landon concoururent pour la présidence des États-Unis. Juste avant l'élection, le journal *Literary Digest* réalisa un sondage de grande ampleur : 10 millions de bulletins de sondage sont distribués aux abonnés du magazine et à des gens figurant au bottin téléphonique. Après plus de 2 millions de réponses, Alfred Landon est annoncé président des États-Unis !

■ Exercice 2.8 Écart-moyen et écart-type

On appelle écart-moyen de la série statistique $(x_i)_{i=1,\dots,n}$ le réel

$$e = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}.$$

Démontrer que l'écart-moyen est toujours inférieur ou égal à l'écart-type σ_x (conseil : utiliser l'inégalité de Cauchy-Schwarz).

■ Exercice 2.9 Minimisation d'écarts - d'après CAPES 2013

Soit n un entier naturel et $(x_1, \dots, x_n)$ un n -uplet de réels. On souhaite trouver un réel x minimisant la somme des écarts ou la somme des écarts au carré. On définit donc sur $\mathbb{R}$ les deux fonctions G et L par :

$$\begin{aligned} G(x) &= \sum_{i=1}^n (x - x_i)^2 \\ L(x) &= \sum_{i=1}^n |x - x_i|. \end{aligned}$$

1. Minimisation de G .

- (a) En écrivant $G(x)$ sous la forme d'un trinôme du second degré, démontrer que la fonction G admet un minimum sur $\mathbb{R}$ et indiquer en quelle valeur de x il est atteint.

- (b) Que représente d'un point de vue statistique la valeur de x trouvée à la question précédente ?
2. Minimisation de L . On suppose désormais que la série est ordonnée, c'est-à-dire que $x_1 \leq x_2 \leq \dots \leq x_n$.
- Représenter graphiquement la fonction L dans le cas où $n = 3$, $x_1 = -2$, $x_2 = 3$, $x_3 = 4$.
 - Représenter graphiquement la fonction L dans le cas où $n = 4$, $x_1 = -2$, $x_2 = 3$, $x_3 = 4$, $x_4 = 7$.
 - Démontrer que la fonction L admet un minimum sur $\mathbb{R}$ et indiquer pour quelle(s) valeur(s) de x il est atteint (on distinguera les cas n pair et n impair).
 - Que représentent, d'un point de vue statistique, les valeurs de x trouvées à la question précédente ?

■ Exercice 2.10 Sur les indicateurs de dispersion

Soit $x_1, \dots, x_N$ une série statistique de N nombres réels (non nécessairement rangés par ordre croissant). On note m la moyenne de la série et σ son écart-type.

- Soit n le nombre d'éléments de la série statistique compris entre $m - 2\sigma$ et $m + 2\sigma$. Montrer que $\sum_{k=1}^n (x_k - m)^2 \geq 4(N - n)\sigma^2$.
 - En déduire qu'au moins les trois quarts des éléments de la série statistique sont compris entre $m - 2\sigma$ et $m + 2\sigma$.
- Plus généralement, montrer que pour tout réel $t > 1$, l'intervalle $[m - t\sigma, m + t\sigma]$ contient au moins une proportion $1 - \frac{1}{t^2}$ des éléments de la série statistique.

■ Exercice 2.11 Algorithme et moyenne

- Écrire un algorithme qui calcule la moyenne d'une série statistique. Il demandera à l'utilisateur (par l'instruction LIRE) l'effectif de cette série et ensuite chacun des éléments de cette série.
- Modifier l'algorithme pour qu'il calcule de plus la variance.

■ Exercice 2.12 Sur le coefficient de corrélation linéaire

Soit $x = (x_i)_{1 \leq i \leq n}$ et $y = (y_i)_{1 \leq i \leq n}$ deux séries statistiques de variance non nulle. On rappelle que le coefficient de corrélation linéaire des deux séries x et y est défini par

$$\rho_{x,y} = \frac{\sigma_{x,y}}{\sigma_x \sigma_y} \text{ où } \sigma_{x,y} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

- Interpréter $\rho_{x,y}$ à l'aide du produit scalaire et de la norme de vecteurs de $\mathbb{R}^n$.
- En déduire que $\rho_{x,y} \in [-1, 1]$.
- Démontrer que $|\rho_{x,y}| = 1$ si et seulement s'il existe $a, b \in \mathbb{R}$ tels que, pour tout $i = 1, \dots, n$, $y_i = ax_i + b$.

■ Exercice 2.13 La méthode des moindres carrés

On considère une série statistique double $\{(x_i, y_i)_{1 \leq i \leq n}\}$ vue comme n points de $\mathbb{R}^2$ et on note M_i le point de coordonnées (x_i, y_i) . On cherche une droite de la forme $y = ax + b$ qui réalise le "meilleur ajustement" possible du nuage. La méthode des moindres carrés consiste à dire que le meilleur ajustement est réalisé lorsque la somme des carrés des distances de M_i à H_i (le projeté de M_i sur la droite $y = ax + b$ parallèlement à l'axe des ordonnées) est minimale. Autrement dit, on cherche à minimiser la quantité suivante :

$$T(a, b) = \sum_{i=1}^n (y_i - ax_i - b)^2.$$

On va prouver dans cet exercice le résultat suivant :

Si $\sigma_x \neq 0$, il existe une unique droite d'équation $y = ax + b$ minimisant la quantité $T(a, b)$. De plus,

$$a = \frac{\sigma_{x,y}}{\sigma_x^2} \text{ et } b = \bar{y} - \bar{x} \frac{\sigma_{x,y}}{\sigma_x^2}.$$

1. Pourquoi impose-t-on la condition $\sigma_x \neq 0$?

2. Méthode 1 : par un calcul direct

(a) On suppose pour commencer que $\bar{x} = 0$ et que $\bar{y} = 0$. Démontrer que

$$T(a, b) = \sum_{i=1}^n y_i^2 + a^2 \sum_{i=1}^n x_i^2 - 2a \sum_{i=1}^n x_i y_i + nb^2.$$

(b) En déduire que $T(a, b)$ est minimum si et seulement si $a = \frac{\sigma_{x,y}}{\sigma_x^2}$ et $b = 0$.

(c) Cas général : on pose $x'_i = x_i - \bar{x}$, $y'_i = y_i - \bar{y}$ et $U(a, b) = \sum_{i=1}^n (y'_i - ax'_i - b)^2$. Démontrer que $T(a, b) = U(a, b - \bar{y} + a\bar{x})$.

(d) Conclure.

3. Méthode 2 : par projection orthogonale. On munit $\mathbb{R}^n$ de son produit scalaire canonique.

(a) Soit $\vec{y}$ un vecteur de $\mathbb{R}^n$ et F un plan vectoriel (de dimension 2). Démontrer que

$$\inf\{\|\vec{y} - \vec{z}\|; \vec{z} \in F\} = \|\vec{y} - p_F(\vec{y})\|$$

où $p_F(\vec{y})$ est le projeté orthogonal de $\vec{y}$ sur F .

(b) On note $\vec{x} = (x_1, \dots, x_n)$, $\vec{y} = (y_1, \dots, y_n)$ et $\vec{u} = (1, \dots, 1)$. Déterminer a et b de sorte que $a\vec{x} + b\vec{u}$ soit le projeté orthogonal de $\vec{y}$ sur $\text{vect}(\vec{x}, \vec{u})$.

(c) Vérifier que $T(a, b) = \|\vec{y} - (a\vec{x} + b\vec{u})\|^2$.

(d) Conclure.

■ Exercice 2.14 Prédiction

L'étude d'une réaction chimique en fonction du temps a donné les résultats suivants :

Temps t (en h)	1	2	3	4	5
Concentration C (en g/L)	6,25	6,71	7,04	7,75	8,33

Des considérations théoriques laissent supposer que la concentration C et le temps t sont liés par une relation de la forme $C = \frac{1}{at+b}$. Donner une estimation de la concentration après 6H.

■ Exercice 2.15 Droite des moindres carrés, dans les deux sens !

On considère une série statistique à deux variables $\{(x_i, y_i); 1 \leq i \leq n\}$. On note D_1 la droite de régression de Y par rapport à X et D_2 la droite de régression de X par rapport à Y . Démontrer que $D_1 = D_2$ si et seulement si tous les points (x_i, y_i) sont alignés.

■ Exercice 2.16 Avec l'ordinateur

Le tableau ci-dessous donne la production annuelle d'une usine de pâte à papier (en tonnes) en fonction de l'année.

2004	2005	2006	2007	2008	2009	2010	2011
325	351	382	432	478	538	708	930

1. Tracer le nuage de points correspondant (sous logiciel!).
2. Un ajustement affine vous semble-t-il adéquat ?
3. Pour chaque année, on note p_i la production de la pâte à papier et $m_i = \ln(p_i)$. Tracer le nouveau nuage de points (i, m_i) et calculer le coefficient de corrélation linéaire de la série double (i, m_i) . Qu'en pensez-vous ?
4. Donner une équation de la droite d'ajustement par les moindres carrés de m_i en i .
5. Quelle production peut-on prévoir en 2014 ?
6. À cette dernière question, voici la réponse de quelques élèves :

Élève A : Je remplace 2014 dans l'équation $0,14x - 280,5$: je trouve 1,46. Puis je prends l'exponentielle : on trouve 4,3. Il doit y avoir une erreur car ce n'est pas assez.

Élève B : Puisque $p = e^{0,143i-280,508}$, alors $p(2014) \simeq 1797$. La production est de 1797 tonnes.

Élève C : J'utilise la touche Stats de ma calculatrice et je trouve 1233 tonnes.

Élève D : Je sais que $x = 2014$ et $p = 77,79x - 155636,82$. Donc : $p = 77,79 \times 2014 - 155636,82 = 1032,24$. La production est 1032,24 tonnes

Analysez la production de chaque élève en mettant en évidence ses réussites et en indiquant l'origine éventuelle de ses erreurs.