

Probabilités — CM3

Loi des grands nombres, théorème central limite et loi normale

1. Le problème : peut-on deviner une élection avec 500 sondés ?

Cadre. Une élection oppose deux candidats A et B dans une population de plusieurs millions d'électeurs. Chaque électeur a un vote déterministe (A ou B). La proportion *réelle* de votants pour B est un nombre $p \in [0, 1]$ **inconnu**, et c'est précisément ce qu'on cherche à estimer **avant** le jour du scrutin.

On interroge n électeurs, *tirés au hasard* dans la population (en prenant soin de « panacher » : région, âge, profession. . . , pour que l'échantillon soit représentatif). À chaque sondé i on associe

$$X_i = \begin{cases} 1 & \text{si l'électeur } i \text{ vote B,} \\ 0 & \text{si l'électeur } i \text{ vote A.} \end{cases}$$

Question 1. Quelle loi suit X_i ? Donner $\mathbb{E}(X_i)$ et $\text{Var}(X_i)$ en fonction de p .

Question 2. Ces variables aléatoires $X_1, \dots, X_n$ sont-elles indépendantes ? Suivent-elles toutes la même loi ?

On dit que les X_i sont **i.i.d.** (indépendantes, identiquement distribuées). On note $m = \mathbb{E}(X_1) = p$ et $\sigma^2 = \text{Var}(X_1) = p(1 - p)$.

On introduit la **moyenne empirique** :

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}.$$

Question 3. À quoi correspond, en mots, la somme $X_1 + \dots + X_n$? Et $\bar{X}_n$?

*Si je sonde 500 personnes soigneusement panachées et que j'observe 52 % d'intentions de vote pour B, puis-je en déduire que B va gagner ?
Et si j'en sondais seulement 100 ? Ou 10 000 ?*

Les deux questions centrales du cours.

1. Vers quoi tend $\bar{X}_n$ quand $n \rightarrow +\infty$? (loi des grands nombres)
2. Pour n fini, à quelle distance de p est $\bar{X}_n$? À $\pm 1\%$ près ? À $\pm 5\%$ près ? (théorème central limite)

Ces deux questions se posent en fait dans tous les problèmes de mesures répétées (contrôle qualité, métrologie, physique expérimentale, machine learning...). On les traitera ici sur le *fil rouge* des sondages.

2. Loi des grands nombres

Théorème (Loi des grands nombres). Soient $X_1, X_2, \dots$ des variables aléatoires **i.i.d.** admettant une espérance $m = \mathbb{E}(X_1)$. Alors

$$\bar{X}_n = \frac{X_1 + \dots + X_n}{n} \xrightarrow[n \rightarrow +\infty]{} m.$$

Interprétation. Si on *moyenne* un grand nombre de réalisations indépendantes de la même expérience, on se rapproche de l'espérance théorique.

Question 1. Appliquer la LGN au cas du sondage : vers quoi tend $\bar{X}_n$? Interpréter cette limite en une phrase.

Question 2. On lance une pièce **équilibrée** un grand nombre de fois. Que dit la LGN sur la fréquence de Pile ? Et si le lancé concerne un dé à 6 faces équilibré, que dit-elle sur la moyenne des résultats ?

Question 3 — Ce que la LGN ne dit pas. La LGN garantit la convergence à *l'infini*. Mais pour $n = 500$, que dit-elle *quantitativement* sur la distance $|\overline{X}_n - p|$?

3. La loi normale

On introduit ici la **loi normale** (ou **gaussienne**), qui apparaîtra naturellement dans le TCL (§ 4).

3.1. Densité et dessin

Définition. Pour $\mu \in \mathbb{R}$ et $\sigma > 0$, on dit que $X \sim \mathcal{N}(\mu, \sigma^2)$ lorsque X admet pour densité


$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Un calcul d'intégrale (admis) donne alors

$$\mathbb{E}(X) = \mu, \quad \text{Var}(X) = \sigma^2, \quad \sigma(X) = \sigma.$$

Question 1. Montrer que f est bien une fonction positive symétrique autour de μ , c'est-à-dire $f(\mu+h) = f(\mu-h)$ pour tout $h \in \mathbb{R}$.

Question 2. Pour quelle valeur de x la densité f atteint-elle son maximum ? Que vaut alors $f(x)$?



Question 3. Soit $X \sim \mathcal{N}(10, 4)$. Donner $\mathbb{E}(X)$, $\text{Var}(X)$ et $\sigma(X)$.

3.2. Cas particulier : la loi normale centrée réduite

Le cas $\mu = 0$ et $\sigma = 1$ est fondamental.

Question 4. Écrire la densité de $\mathcal{N}(0, 1)$ et donner $\mathbb{E}(Z)$, $\text{Var}(Z)$.

3.3. Un problème nouveau : la fonction de répartition

Pour toute loi continue, la fonction de répartition est

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt.$$

Pour la loi normale, on bute sur un obstacle inédit : la **primitive de $e^{-z^2/2}$ n'a pas d'expression élémentaire**. On ne peut donc pas donner F par une formule fermée.

La solution : tabuler la fonction. On donne à la répartition de $\mathcal{N}(0, 1)$ un nom et un symbole propres :

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt, \quad Z \sim \mathcal{N}(0, 1).$$

C'est une **fonction classique**, au même titre que $\exp$, $\log$ ou $\sin$. Elle n'admet pas de formule fermée mais ses valeurs sont **tabulées une fois pour toutes** (§ 6) ou calculées par des algorithmes dans les calculatrices et les logiciels (en Python : `scipy.stats.norm.cdf`).

Question 5. Sans table, calculer $\Phi(0)$. Justifier.

4. Théorème central limite

Le TCL précise *la vitesse* et *la loi* des fluctuations de $\overline{X}_n$ autour de m . C'est le théorème qui répond à la question « à quelle distance de p est $\overline{X}_n$ pour $n = 500$? ».

Théorème central limite (TCL). Soient $X_1, X_2, \dots$ des variables aléatoires **i.i.d.** admettant une espérance m et une variance σ^2 finies. Alors la variable aléatoire

$$Z_n = \frac{\bar{X}_n - m}{\sigma/\sqrt{n}} = \frac{\sqrt{n}}{\sigma}(\bar{X}_n - m)$$

converge *en loi* vers la loi normale centrée réduite $\mathcal{N}(0, 1)$. Autrement dit, pour tous réels $a \leq b$,

$$P(a \leq Z_n \leq b) \xrightarrow[n \rightarrow +\infty]{} \Phi(b) - \Phi(a).$$

Forme ramassée (à retenir). Pour n grand, l'écart $\bar{X}_n - m$ est approximativement gaussien, d'écart-type $\sigma/\sqrt{n}$:



$$\bar{X}_n \approx m + \frac{\sigma}{\sqrt{n}} Z \quad \text{avec} \quad Z \sim \mathcal{N}(0, 1).$$

Question 1 — Vitesse en $1/\sqrt{n}$. Par quel facteur l'écart-type de $\bar{X}_n$ est-il divisé si on multiplie n par 100 ? Et pour diviser l'écart-type par 10, par quel facteur faut-il multiplier n ?

Question 2 — Application au sondage. Dans le cas du sondage, on a $m = p$ et $\sigma^2 = p(1 - p)$. Écrire l'approximation normale de $\bar{X}_n$ donnée par le TCL.

Question 3 — Universalité. Dans l'énoncé du TCL, où intervient la loi précise des X_i dans la limite obtenue ?

Expérience de pensée — planche de Galton. On lâche une bille qui, à chaque rangée de clous (n rangées), dévie de $+1$ ou -1 avec probabilité $1/2$. La position finale $S_n = \varepsilon_1 + \dots + \varepsilon_n$ est comptée en bas.



Le profil des fréquences de S_n prend toujours la même **forme de cloche**, de plus en plus lisse : c'est le TCL à l'œuvre.

5. Standardisation : tout se ramène à $\mathcal{N}(0, 1)$

La table de Φ ne donne que la loi $\mathcal{N}(0, 1)$. Comment calcule-t-on $P(a \leq X \leq b)$ pour $X \sim \mathcal{N}(\mu, \sigma^2)$ quelconque ?

Proposition (standardisation). Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1).$$

Réciproquement, si $Z \sim \mathcal{N}(0, 1)$, alors $X = \mu + \sigma Z \sim \mathcal{N}(\mu, \sigma^2)$.

Idée. Centrer ($X - \mu$ retire la moyenne), puis réduire (diviser par σ pour avoir un écart-type de 1). Z s'interprète comme « le nombre d'écarts-types au-dessus de la moyenne ».

Question 1. Soit $X \sim \mathcal{N}(10, 25)$. Quelle est la loi de $Z = (X - 10)/5$? Et celle de $Y = (X - 10)/25$?

Question 2. Soit $X \sim \mathcal{N}(10, 25)$. Exprimer $P(X \leq 15)$ et $P(X \geq 20)$ en fonction de Φ .

Principe général. Toute probabilité sur $X \sim \mathcal{N}(\mu, \sigma^2)$ se ramène à une probabilité sur Z :

$$P(X \leq x) = P\left(Z \leq \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right).$$

6. Lecture de la table de Φ

La **table** donne $\Phi(z) = P(Z \leq z)$ pour $z \geq 0$ à deux décimales près.

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952

Mode d'emploi. Pour lire $\Phi(1,96)$: ligne 1,9, colonne 0,06. Pour $\Phi(0,53)$: ligne 0,5, colonne 0,03.

Question 1 — Échauffement. Lire dans la table : $\Phi(1)$, $\Phi(1,96)$, $\Phi(2)$ et $\Phi(2,58)$.

Question 2 — Cas $z < 0$. La table ne donne que $z \geq 0$. Comment calculer $\Phi(-a)$ pour $a > 0$? (On s'aidera d'un dessin de la cloche.)

Les quatre réflexes. Pour $Z \sim \mathcal{N}(0, 1)$ et tous réels $a \leq b$:

1. $P(Z \leq a) = \Phi(a)$ (lecture directe si $a \geq 0$).

2. **Symétrie :** $\Phi(-a) = 1 - \Phi(a)$.

3. $P(a \leq Z \leq b) = \Phi(b) - \Phi(a)$.

4. $P(|Z| \leq a) = 2\Phi(a) - 1$ ($a \geq 0$).

Question 3 — Problème d'application. Soit $Z \sim \mathcal{N}(0, 1)$. Calculer :

1. $P(Z \leq -0,58)$.

2. $P(Z \geq 1,96)$.

3. $P(-1 \leq Z \leq 1)$.

4. $P(|Z| \leq 1,96)$ et $P(|Z| \leq 2,58)$.

Règle 68 / 95 / 99. Pour $X \sim \mathcal{N}(\mu, \sigma^2)$:

Intervalle autour de μ	Probabilité
$[\mu - \sigma, \mu + \sigma]$	$\approx 68 \%$
$[\mu - 1,96\sigma, \mu + 1,96\sigma]$	$= 95 \%$
$[\mu - 2,58\sigma, \mu + 2,58\sigma]$	$= 99 \%$
$[\mu - 3\sigma, \mu + 3\sigma]$	$\approx 99,7 \%$

7. Retour aux sondages : combien de personnes sonder ?

On reprend le fil rouge du § 1 : $X_i \in \{0, 1\}$ i.i.d. de Bernoulli $\mathcal{B}(p)$, donc $m = \mathbb{E}(X_i) = p$ et $\sigma^2 = \text{Var}(X_i) = p(1 - p)$. La **fréquence observée** est $\bar{X}_n$, qui estime p .

Question 1 — Appliquer le TCL. Écrire l'approximation normale de $\bar{X}_n$ pour n grand dans ce contexte.

Question 2 — Intervalle de confiance à 95 %. En utilisant la règle des 95 %, montrer que, avec une probabilité d'environ 95 %,

$$|\bar{X}_n - p| \leq 1,96 \sqrt{\frac{p(1-p)}{n}}.$$

Question 3 — Majoration universelle. Étudier la fonction $p \mapsto p(1-p)$ sur $[0, 1]$. En quel point est-elle maximale ? Que vaut alors ce maximum ? En déduire que $\sqrt{p(1-p)/n} \leq 1/(2\sqrt{n})$ pour tout $p \in [0, 1]$.

Marge d'erreur universelle à 95 %. Quelle que soit la valeur vraie de p , avec probabilité $\approx 95\%$,

$$|\bar{X}_n - p| \leq \frac{1,96}{2\sqrt{n}} \approx \frac{1}{\sqrt{n}}.$$

C'est la formule souvent citée dans la presse : « marge d'erreur de $\pm 1/\sqrt{n}$ ».

Problème 1 — Taille d'un sondage. Un institut veut estimer p à $\pm 3\%$ près, avec un niveau de confiance de 95 %. Combien de personnes faut-il sonder ?

Problème 2 — Marge d'erreur en fonction de n . Compléter le tableau suivant ($\varepsilon = 1/\sqrt{n}$) :

n	marge d'erreur ε
100	
500	
1 000	
10 000	
1 000 000	

À retenir. Pour diviser la marge d'erreur par 10, il faut multiplier la taille du sondage par 100. C'est pour cela qu'aucun institut ne va jamais sonder 1 million de personnes : le coût est prohibitif pour une amélioration marginale.

Problème 3 — Retour à la question du § 1. Un sondage sur $n = 500$ personnes donne 52 % d'intentions de vote pour B.

1. Quelle est la marge d'erreur à 95 % ?
2. Peut-on « prédire » la victoire de B ?

3. Même question pour $n = 1\,000$ personnes avec 52 %.
4. Même question pour $n = 10\,000$ personnes avec 52 %.

8. Autres applications du TCL

Problème 4 — Pile ou face. On lance $n = 10\,000$ fois une pièce **équilibrée** et on note S_n le nombre de Pile obtenus. On écrit $S_n = X_1 + \cdots + X_n$ avec $X_i \sim \mathcal{B}(1/2)$ i.i.d.

1. Donner $\mathbb{E}(S_n)$ et $\text{Var}(S_n)$, puis $\sigma(S_n)$.
2. En déduire, grâce au TCL, l'approximation normale de S_n . Quelle est la loi de $Z = (S_n - 5\,000)/50$?
3. Calculer approximativement $P(S_n \geq 5\,100)$. Commenter.
4. Calculer $P(|S_n - 5\,000| \leq 100)$.

Problème 5 — Un dé suspect. On lance un dé à 6 faces et on compte les 6 obtenus. À partir de combien de lancers *sans* aucun 6 peut-on raisonnablement soupçonner que le dé est « truqué » ?

1. Sous l'hypothèse « dé équilibré », donner $\mathbb{E}(S_n)$ et $\sigma(S_n)$, où S_n est le nombre de 6 en n lancers.

2. Combien d'écarts-types sépare « aucun 6 » de la moyenne, en fonction de n ?
3. En déduire l'ordre de grandeur de n à partir duquel l'événement « aucun 6 » est à plus de 3σ de la moyenne.

9. Bilan

À retenir.

1. Pour $X_1, \dots, X_n$ i.i.d., on note $\bar{X}_n = (X_1 + \dots + X_n)/n$.
2. **Loi des grands nombres** : $\bar{X}_n \rightarrow \mathbb{E}(X_1)$ quand $n \rightarrow +\infty$ (*sans information sur la vitesse*).
3. **Loi normale** $\mathcal{N}(\mu, \sigma^2)$: densité en cloche $\frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/(2\sigma^2)}$, d'espérance μ et d'écart-type σ . Sa répartition Φ (pour $\mathcal{N}(0, 1)$) est tabulée.
4. **Théorème central limite** : pour n grand,

$$\bar{X}_n \approx \mathbb{E}(X_1) + \frac{\sigma}{\sqrt{n}} Z, \quad Z \sim \mathcal{N}(0, 1).$$

Vitesse « en $1/\sqrt{n}$ », loi limite **universelle**.

5. **Standardisation** : $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$ ramène tout calcul à la table de Φ .
6. **Réflexes de table** : $\Phi(-a) = 1 - \Phi(a)$, $P(a \leq Z \leq b) = \Phi(b) - \Phi(a)$, $P(|Z| \leq a) = 2\Phi(a) - 1$.
7. **Règle 68 / 95 / 99** : $P(|Z| \leq 1) \approx 0,68$, $P(|Z| \leq 1,96) = 0,95$, $P(|Z| \leq 2,58) = 0,99$.
8. **Sondage binaire de taille n** : marge d'erreur $\pm 1/\sqrt{n}$ à 95 % de confiance.