

Probabilités — CM4

Intervalles de confiance, applications et extensions

1. Un problème concret : le contrôle qualité

Cadre. Une usine produit des sacs de ciment dont le poids nominal est de 25 kg. La machine de remplissage a une variabilité connue et son écart-type est $\sigma = 0,5$ kg. Le chef de production veut s'assurer que la machine n'est pas dérégulée (c'est-à-dire que l'espérance μ du poids des sacs est bien de 25 kg).

Comment faire ?

Il pèse un échantillon de $n = 100$ sacs pris au hasard sur la chaîne de production et obtient un poids moyen empirique $\bar{X}_n = 24,8$ kg.

Question 1. La moyenne obtenue n'est pas exactement 25 kg. Que peut-on affirmer ?

Non. Le remplissage est un phénomène aléatoire. Même si la machine est parfaitement réglée sur $\mu = 25$ kg, la moyenne empirique $\bar{X}_n$ d'un échantillon de 100 sacs va fluctuer autour de 25 kg. Tout l'enjeu est de savoir si l'écart observé (0,2 kg) est "normal" (dû aux fluctuations d'échantillonnage) ou "anormalement grand" (preuve d'un dérèglement).

*Plutôt que de donner une simple estimation ponctuelle ($\mu \approx 24,8$), on veut construire un **intervalle** qui contient la vraie valeur μ avec une probabilité très grande (par exemple 95 %). C'est ce qu'on appelle un **intervalle de confiance**.*

2. Construction d'un intervalle de confiance

Cadre général : un échantillon $X_1, \dots, X_n$ de variables i.i.d. d'espérance μ (inconnue) et d'écart-type σ (supposé connu).

D'après le TCL, pour n assez grand, la variable aléatoire :

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

suit approximativement une loi normale centrée réduite $\mathcal{N}(0, 1)$.

Qu'est-ce que cela signifie ?

Question 1. Soit un niveau de confiance $1 - \alpha$ (par exemple 0,95 pour $\alpha = 0,05$). Justifier à l'aide d'un dessin qu'il existe un unique réel $t_\alpha > 0$ tel que pour $Z \sim \mathcal{N}(0, 1)$, on ait :

$$P(-t_\alpha \leq Z \leq t_\alpha) = 1 - \alpha$$

La densité de la loi normale centrée réduite est une cloche symétrique par rapport à 0. L'aire totale sous la courbe vaut 1. On cherche un intervalle $[-t_\alpha, t_\alpha]$ centré en 0 tel que l'aire sous la courbe entre ces deux bornes vaille $1 - \alpha$. Par symétrie, il y a une aire de $\alpha/2$ à gauche de $-t_\alpha$ et une aire de $\alpha/2$ à droite de t_α .

Question 2. À partir de la table de la loi normale, trouver $t_{0,05}$ (pour un niveau de confiance de 95 %) et $t_{0,01}$ (pour 99 %).

Si l'aire centrale est de $1 - \alpha$, l'aire totale à gauche de t_α est $\Phi(t_\alpha) = (1 - \alpha) + \alpha/2 = 1 - \alpha/2$.

— Pour 95 % ($\alpha = 0,05$) : $\Phi(t) = 1 - 0,025 = 0,975$. La table donne $t_{0,05} = 1,96$.

— Pour 99 % ($\alpha = 0,01$) : $\Phi(t) = 1 - 0,005 = 0,995$. La table donne $t_{0,01} \approx 2,58$.

Question 3. En remplaçant Z par l'expression du TCL Z_n , isoler μ dans l'inégalité $-t_\alpha \leq Z_n \leq t_\alpha$ pour aboutir à un encadrement de μ .

On part de :

$$-t_\alpha \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq t_\alpha$$

On multiplie par $\sigma/\sqrt{n}$:

$$-t_\alpha \frac{\sigma}{\sqrt{n}} \leq \bar{X}_n - \mu \leq t_\alpha \frac{\sigma}{\sqrt{n}}$$

On multiplie par -1 (ce qui inverse le sens des inégalités, mais l'encadrement reste symétrique) et on ajoute $\bar{X}_n$:

$$\bar{X}_n - t_\alpha \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + t_\alpha \frac{\sigma}{\sqrt{n}}$$

Formule de l'intervalle de confiance (IC) pour la moyenne. Avec une probabilité de $1 - \alpha$, la vraie moyenne μ appartient à l'intervalle :

$$IC_{1-\alpha} = \left[\bar{X}_n - t_\alpha \frac{\sigma}{\sqrt{n}} ; \bar{X}_n + t_\alpha \frac{\sigma}{\sqrt{n}} \right]$$

Question 4. Retour au problème initial de l'usine : calculer l'intervalle de confiance à 95 % pour la vraie moyenne μ produite par la machine. La machine est-elle déréglée ?

On applique la formule avec $t_{0,05} = 1,96$:

$$\mu \in \left[24,8 - 1,96 \frac{0,5}{10} ; 24,8 + 1,96 \frac{0,5}{10} \right]$$

$$\mu \in [24,8 - 0,098 ; 24,8 + 0,098] = [24,702 ; 24,898]$$

L'intervalle à 95 % de confiance ne contient pas la valeur 25. Il est donc très improbable (moins de 5 % de chances) que la machine soit bien réglée. On conclut qu'elle est **dérégulée**.

3. Application : Estimation d'une proportion

On souhaite estimer une proportion p dans une population (ex : intentions de vote, proportion de pièces défectueuses). On observe une proportion empirique $\hat{p} = \bar{X}_n$ sur un échantillon de taille n . On se rappelle que $\mu = p$ et $\sigma = \sqrt{p(1-p)}$.

Question 1. Appliquer la formule de l'intervalle de confiance de la partie 2 pour donner l'intervalle de confiance à un niveau $1 - \alpha$ pour la proportion p .

En remplaçant $\bar{X}_n$ par $\hat{p}$ et σ par $\sqrt{p(1-p)}$, on obtient :

$$p \in \left[\hat{p} - t_\alpha \frac{\sqrt{p(1-p)}}{\sqrt{n}} ; \hat{p} + t_\alpha \frac{\sqrt{p(1-p)}}{\sqrt{n}} \right]$$

Le problème : Les bornes de cet intervalle dépendent de p , qui est justement ce qu'on cherche à estimer ! On ne peut donc pas le calculer.

Question 2. Proposer deux méthodes pour contourner ce problème.

Méthode 1 (optimiste) : On remplace le p inconnu dans l'écart-type par son estimation $\hat{p}$. L'intervalle devient :

$$\left[\hat{p} - t_\alpha \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} ; \hat{p} + t_\alpha \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \right]$$

Méthode 2 (pessimiste/rigoureuse) : On majore $\sqrt{p(1-p)}$. La fonction $x \mapsto x(1-x)$ atteint son maximum en $1/2$ et vaut au maximum $1/4$. Donc $\sqrt{p(1-p)} \leq 1/2$. L'intervalle, légèrement élargi, devient :

$$\left[\hat{p} - \frac{t_\alpha}{2\sqrt{n}} ; \hat{p} + \frac{t_\alpha}{2\sqrt{n}} \right]$$

Question 3. Lors d'un sondage sur 1000 personnes, 520 déclarent vouloir voter pour le candidat A. Donner l'intervalle de confiance à 95 % rigoureux. A-t-on la garantie à 95 % qu'il va gagner ?

Ici $n = 1000$ et $\hat{p} = 0,52$. Pour 95 %, $t_\alpha = 1,96$. La demi-largeur de l'intervalle est $\frac{1,96}{2\sqrt{1000}} \approx 0,031$ (3,1 %). L'intervalle est donc $[0,52 - 0,031 ; 0,52 + 0,031] = [0,489 ; 0,551]$. L'intervalle contient 0,50. On ne peut donc pas garantir la victoire du candidat A à 95 %.

4. Début d'extensions : Tests et autres lois

4.1. Principe d'un test d'hypothèse

Un vendeur d'ampoules prétend que la durée de vie moyenne de ses ampoules est de 1000 heures, avec un écart-type de 100 heures. Vous testez 50 ampoules et obtenez une durée de vie moyenne de 950 heures.

Question 1. Si le vendeur dit la vérité, quelle est la loi approximative suivie par la moyenne $\bar{X}_n$ sur 50 ampoules ?

D'après le TCL, si $\mu = 1000$ et $\sigma = 100$, alors :

$$\bar{X}_n \approx \mathcal{N}\left(1000, \frac{100^2}{50}\right)$$

L'écart-type de $\bar{X}_n$ est $\sigma/\sqrt{n} = 100/\sqrt{50} \approx 14,14$ heures.

Question 2. Calculer la probabilité d'obtenir une moyenne inférieure ou égale à 950 heures si le vendeur dit vrai. Que concluez-vous ?

On cherche $P(\bar{X}_n \leq 950)$. On standardise :

$$P\left(Z \leq \frac{950 - 1000}{14,14}\right) = P(Z \leq -3,53)$$

D'après la table de la loi normale, $\Phi(-3,53) \approx 0$. Il est quasiment impossible d'obtenir une telle moyenne si le vendeur dit vrai. On rejette donc l'hypothèse du vendeur : ses ampoules durent moins longtemps qu'annoncé.

4.2. La loi exponentielle

La loi exponentielle de paramètre $\lambda > 0$, notée $\mathcal{E}(\lambda)$, modélise souvent un temps d'attente ou une durée de fonctionnement continue. Elle prend ses valeurs dans $[0, +\infty[$ et sa densité de probabilité est :

$$f(x) = \lambda e^{-\lambda x}$$

Question 3. Calculer l'espérance et la variance d'une variable aléatoire $X \sim \mathcal{E}(\lambda)$.

On a vu (ou on admet) que pour une loi exponentielle :

$$\mu = \mathbb{E}(X) = \frac{1}{\lambda} \quad \text{et} \quad \sigma^2 = \text{Var}(X) = \frac{1}{\lambda^2}$$

4.3. Estimer le paramètre d'une loi

Le TCL s'applique indépendamment de la loi d'origine des données. Supposons qu'un centre d'appels veuille modéliser la durée de ses appels. On fait l'hypothèse que cette durée suit une loi exponentielle $\mathcal{E}(\lambda)$.

Question 4. Si on observe une durée moyenne empirique $\bar{X}_n = 5$ minutes sur un grand nombre d'appels, quel estimateur $\hat{\lambda}$ naturel pouvez-vous proposer pour le paramètre λ ?

Puisque l'espérance est $\mu = \frac{1}{\lambda}$ et que $\overline{X}_n$ est un bon estimateur de l'espérance μ , on peut estimer λ en prenant l'inverse de la moyenne empirique :

$$\hat{\lambda} = \frac{1}{\overline{X}_n} = \frac{1}{5} = 0,2 \text{ appel/minute}$$