

Les jurés dans un tribunal se pose la question:

Un accusé arrive présumé innocent -
(Hypothèse de départ H_0)

L'accusation amène des éléments -

A-t-on assez d'éléments pour rejeter l'hypothèse
si oui, on déclare coupable

Probabilités — CM5

Tests d'hypothèses : à partir de quand être surpris ?

1. Un problème : faut-il être surpris ?

Cadre. Vous êtes au volant sur l'autoroute. Vous savez (statistiques constructeurs) qu'en France, environ 10 % des voitures sont **rouges**. Soudain, vous croisez 4 **voitures rouges de suite**.

*À partir de quand commence-t-on à douter du modèle
« les couleurs des voitures qui passent sont indépendantes,
chacune rouge avec probabilité 0,10 » ?*

Question 1. Sous ce modèle, quelle est la probabilité de croiser 4 voitures rouges *exactement* d'affilée ?

$$P = (0,1)^4 = \frac{1}{10\,000}$$

Question 2. Et pour 7 voitures rouges d'affilée ?

$$P = (0,1)^7 = \frac{1}{10\text{ millions}}$$

*on rejette l'hypothèse —
il y a un festival de voitures
rouges → pas d'indépendance*

La logique du test d'hypothèse — en quatre temps.

1. **Hypothèse de référence** (H_0). On pose un modèle « par défaut » dont on veut éprouver la crédibilité (ici : indépendance + $p = 0,10$).
2. **Observation**. On collecte des données (ici : 4 rouges de suite).
3. **Probabilité sous** H_0 . On calcule la probabilité, *en supposant* H_0 *vraie*, d'observer un résultat « au moins aussi extrême » que celui constaté. C'est la **p-value**.
4. **Décision**. Si cette probabilité est *très petite* (sous un seuil α fixé à l'avance), on **rejette** H_0 : les données sont incompatibles avec le modèle. Sinon, on *conserve* H_0 par défaut.

Remarque. On ne « prouve » jamais qu'une hypothèse est vraie. On peut seulement décider qu'elle est trop incompatible avec les données pour être maintenue. Comme au tribunal : on rejette la présomption d'innocence (au-delà d'un doute raisonnable) ou bien on l'**accepte par défaut** — ce n'est pas pareil que « prouver que l'accusé est innocent ».

1.1. Deuxième exemple : un dé sans aucun 6

On lance un dé à 6 faces 20 fois de suite et, à notre grande surprise, on n'obtient **aucun** 6. Doit-on suspecter que le dé est truqué ?

Question 1. Énoncer l'hypothèse H_0 (« ~~le dé n'est pas truqué~~ ») et proposer une statistique de test naturelle. Quelle est sa loi sous H_0 ?

H_0 : « le dé n'est pas truqué ». On se fixe un seuil à 1%
 loi géométrique: Nbre d'essais pour voir le premier 6.
 $X \sim \mathcal{G}(1/6)$ il s'est passé $X=20$

Question 2. On observe $X_{\text{obs}} = 20$. Calculer la p-value et conclure au seuil $\alpha = 1\%$.

tableau donné

p-value ici = $P(X \geq 20)$ avec $X \sim \mathcal{G}(1/6)$

k	10	15	20	25	30	$P(X \geq 20)$
$P(X \leq k)$	0,84	0,94	0,97	0,99	1	$= 1 - P(X < 20)$

$\rightarrow P(X \leq 20) = 0,97$ $\sim 3\%$

2. Formalisation : hypothèse, p-value, décision

On ne rejette pas l'hypothèse

Vocabulaire.

- **Hypothèse nulle** H_0 : l'hypothèse « par défaut » qu'on cherche à mettre à l'épreuve.
- **Hypothèse alternative** H_1 : ce qui reste si H_0 est fausse.
- **Statistique de test** : une quantité calculée sur l'échantillon, dont on connaît la loi sous H_0 . $\rightarrow$ *Notre variable X*
- **p-value** : probabilité, sous H_0 , d'observer un résultat au moins aussi extrême que celui qu'on a obtenu.
- **Seuil** α : seuil de tolérance (typiquement 5% ou 1%). On rejette H_0 si p-value $< \alpha$.

Question 1. Dans l'exemple des voitures, quelles sont H_0 et H_1 ? Quelle p-value obtient-on avec 4 rouges d'affilée ? Au seuil $\alpha = 0,05$, rejette-t-on H_0 ?

Le test d'hypothèse, c'est partout. Le même squelette « hypothèse de référence → statistique → p-value → décision » se retrouve dans une foule de domaines très différents. Pour chacun des contextes ci-dessous, à toi de proposer l'hypothèse H_0 .

Exemple 1 — Médecine. On veut tester un nouveau traitement contre l'hypertension. On recrute deux groupes de 200 patients : l'un reçoit le médicament, l'autre un placebo. Au bout de 3 mois, la baisse moyenne de tension est de 9 mmHg dans le premier groupe contre 7 mmHg dans le second. Cette différence est-elle réelle, ou s'explique-t-elle par le simple hasard de l'échantillonnage ?

H_0 : "La molécule n'est pas plus efficace que le placebo"
l'observation permettrait-elle de rejeter H_0 et valider la molécule -

Exemple 2 — Contrôle qualité. Une chaîne de production garantit au plus 1 % de boulons défectueux. Un client effectue une réception : il prélève 500 boulons et en trouve 11 défectueux (2,2 %). Le lot doit-il être refusé ?

H_0 : "il y a au plus 1% de boulons défectueux dans le lot"
Calculons les probas :-

Exemple 3 — A/B testing. Le service marketing d'un site marchand teste deux versions de la page d'accueil. La version A est montrée à 10 000 visiteurs (320 achats), la version B à 10 000 autres (360 achats). Faut-il déployer la version B partout ?

H_0 : "les deux versions ont le même taux de conversion"
Si mes observations ont peu de chances d'arriver sous cette hypothèse, c'est que B est meilleur -

Exemple 4 — Sondage électoral. À 48 % d'intentions de vote sur un échantillon de 1000 personnes, le candidat peut-il être assuré qu'il franchira la barre des 50 % au second tour ?

H_0 : "le candidat dépasse les 50%"
On va calculer la probabilité d'avoir obtenu 48% au sondage si H_0 est vrai -

Exemple 5 — Détection de fraude. Dans une comptabilité « naturelle », le premier chiffre d'un montant suit la loi de Benford (1 → 30 %, 2 → 18 %, ..., 9 → 4,5 %). Un enquêteur compare la distribution des premiers chiffres d'une déclaration suspecte à cette loi.

H_0 : "l'entreprise n'a pas fraudé"
si les données de l'entreprise s'éloignent trop de la loi de Benford, on rejette H_0 .

Exemple 2 — Contrôle qualité. Une chaîne de production garantit au plus 1% de boulons défectueux. Un client effectue une réception : il prélève 500 boulons et en trouve 11 défectueux (2,2%). Le lot doit-il être refusé ?

H_0 : "il y a au plus 1% de boulons défectueux dans le lot"

Seuil pour rejeter H_0 : $\alpha = 1\%$

Nombre de boulons défectueux dans le lot : X ^{n} ^{p}
Sous H_0 , X suit la loi Binomiale $(500, 1\%)$
On a vu $X=11$. $p\text{-value} = P(X \geq 11)$

k	8	9	10	11	12
$P(X \leq k)$	0,932	0,970	0,988	0,996	0,999

$$\begin{aligned} P(X \geq 11) &= 1 - P(X < 11) \\ &= 1 - P(X \leq 10) = 12\% \end{aligned}$$

On ne rejette pas H_0



Quelques seuils α « publics ». Le seuil dépend des conséquences d'une fausse découverte :

- **Sciences sociales, médecine usuelle** : $\alpha = 5\%$ (par convention).
- **Essais cliniques de phase III (FDA, EMA)** : typiquement $\alpha = 5\%$, mais on demande *deux études indépendantes positives* avant de mettre un médicament sur le marché.
- **Études génomiques (GWAS)** : $\alpha \approx 5 \cdot 10^{-8}$, pour corriger les $\sim 10^6$ tests menés simultanément sur le génome.
- **Physique des particules (CERN)** : pour annoncer une « découverte » (boson de Higgs, 2012), il faut 5σ , soit $p\text{-value} < 3 \cdot 10^{-7}$.

Plus l'enjeu est lourd (autoriser un médicament, annoncer une particule fondamentale), plus le seuil est sévère.

Attention au p -hacking. Pour que la p -value ait du sens, le seuil α et la statistique de test doivent être fixés **avant** de regarder les données. Sinon, on tombe dans des pratiques qui fabriquent artificiellement des résultats « significatifs » :

- **Tester 20 hypothèses, garder celle qui marche.** Au seuil 5% , on s'attend à 1 résultat « positif » par pur hasard sur 20, même quand tout est faux.
- **Stopper la collecte dès que $p < 0,05$.** En continuant à observer juste assez, on finit toujours par franchir le seuil.
- **Découper en sous-groupes après coup.** « Le médicament ne marche pas en moyenne, mais marche *chez les femmes de plus de 50 ans* » : avec assez de découpages, une catégorie sera « positive » par hasard.

C'est l'une des causes de la *crise de reproductibilité* en sciences (beaucoup de résultats publiés ne se confirment pas en répétant l'expérience).

3. Test sur une moyenne

On revient sur l'exemple central du CM4 : une usine remplit des sacs de ciment de poids nominal 25 kg, avec un écart-type de remplissage $\sigma = 0,5$ kg *connu*. Le chef de production veut savoir si la machine est **dérégulée**.

Il pèse $n = 100$ sacs et obtient une moyenne empirique $\bar{X}_n = 24,8$ kg.

Question 1. Quelles sont H_0 et H_1 dans ce problème ?

H_0 : « la moyenne de la machine est 25 kg »

Question 2. En utilisant le TCL, construire une **statistique de test** Z qui suit $\mathcal{N}(0, 1)$ sous H_0 . Calculer la valeur observée Z_{obs} .

TCL: $\frac{\sqrt{n}}{\sigma} (\bar{X}_n - \mu) \sim \mathcal{N}(0, 1)$

⚡ sous l'hypothèse $H_0: \mu = 25$

On peut calculer $\frac{\sqrt{100}}{0,5} (24,8 - 25) = -4$


p-value: $P(Z \leq -4)$
 $= 1 - \Phi(4)$ presque 0%
 on rejette H_0

~~Question 3. Quelle est la p-value? Conclure au seuil $\alpha = 5\%$.~~

Démarche : * ~~Poser H_0~~

* Sous H_0 on a une quantité dont on connaît la loi
 * Avec les données on calcule ce que vaut cette quantité
 * On regarde à quel point c'est rare d'avoir obtenu cette valeur pour cette loi.

ici une loi $\mathcal{N}(0, 1)$ qui donne -4, c'est très improbable
 zone d'acceptation (on garde H_0)



Recette du test sur une moyenne (σ connu).

1. $H_0 : \mu = \mu_0$ contre $H_1 : \mu \neq \mu_0$.
2. Statistique : $Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$, qui suit $\mathcal{N}(0, 1)$ sous H_0 .
3. Seuil α (souvent 0,05) $\Rightarrow$ valeur critique t_α (par exemple $t_{0,05} = 1,96$).
4. **Décision** : rejeter H_0 si $|Z_{\text{obs}}| > t_\alpha$, sinon ne pas rejeter.

3.1. Exercice : ce dé est-il pipé ? (test du χ^2) ^{"khi deux"}

Au-delà de la moyenne. Le test précédent compare une moyenne empirique à une valeur attendue. On veut souvent tester quelque chose de plus riche : « les fréquences observées d'un phénomène réparti en plusieurs catégories sont-elles compatibles avec celles attendues sous un modèle de référence ? » C'est le rôle du **test du khi-deux d'adéquation** (Karl Pearson, 1900).

Quelques applications classiques.


- **Adéquation à une loi de référence** : un dé est-il équilibré ? les premiers chiffres d'une comptabilité suivent-ils la loi de Benford ?
- **Indépendance entre deux variables qualitatives** : la couleur des yeux dépend-elle du sexe ? le secteur d'activité dépend-il de la région ?

— **Homogénéité entre populations** : la répartition des opinions est-elle la même chez les ≤ 30 ans et les ≥ 60 ans ?

La loi du khi-deux $\chi^2(k)$. Si $U_1, \dots, U_k$ sont k variables indépendantes de loi $\mathcal{N}(0,1)$, alors par définition

$$U_1^2 + U_2^2 + \dots + U_k^2 \sim \chi^2(k).$$

On l'appelle « loi du khi-deux à k degrés de liberté ». Elle ne prend que des valeurs positives, son espérance vaut k , son écart-type $\sqrt{2k}$. Plus la valeur observée s'éloigne de k vers la droite, plus elle est *suspecte*.



Statistique du test d'adéquation. On dispose d'un échantillon de taille n réparti en r catégories d'effectifs observés $O_1, \dots, O_r$. Sous H_0 (« les données suivent telle loi de référence »), on calcule les effectifs *attendus* $E_1, \dots, E_r$, puis

$$\chi_{\text{obs}}^2 = \sum_{i=1}^r \frac{(O_i - E_i)^2}{E_i}.$$

On admet (théorème de Pearson) que sous H_0 et pour n grand, χ_{obs}^2 suit approximativement une loi $\chi^2(r-1)$. La p-value est $P(\chi^2(r-1) \geq \chi_{\text{obs}}^2)$: on rejette si elle est petite, c'est-à-dire si l'écart entre observé et attendu est *trop grand* pour être imputé au hasard.

Énoncé. Un joueur soupçonne son dé à 6 faces d'être pipé. Il le lance $n = 600$ fois et observe :

Face i	1	2	3	4	5	6
Effectif observé O_i	75	90	100	110	100	125

on fixe seul $\alpha = 1\%$

Question 1. Quelles sont H_0 et H_1 ? Sous H_0 , donner les effectifs attendus E_i pour chaque face.

H_0 : "Le dé n'est pas truqué".

sous H_0 , pour 600 lancers, on devrait voir

Face i	1	2	3	4	5	6
Effectifs théoriques	100	100	100	100	100	100

Question 2. Calculer la statistique χ_{obs}^2 .

$$\chi_{\text{obs}}^2 = \sum_{i=1}^6 \frac{(O_i - E_i)^2}{E_i} = \frac{(100-75)^2}{100} + \frac{(100-90)^2}{100} + \dots$$


$$= 14,5$$

Quelle loi suit χ^2_{obs} ? c'est une loi du khi-2 à 5 degrés de liberté.
 tableau CDF (cumulative distribution function = Fonction de répartition)

x	9	10	11	12	13	14	14,5	15	16
$F(x) = P(\chi^2(5) \leq x)$	0,891	0,925	0,949	0,965	0,977	0,984	0,987	0,990	0,993

Question 3. Quel est le nombre de degrés de liberté? Comparer χ^2_{obs} à l'espérance d'une loi $\chi^2(k)$ sous H_0 . Cela paraît-il « normal » ou « suspect »?

p-valeur: $P(X \geq 14,5)$
 $= 1 - P(X < 14,5)$
 $= 1 - P(X \leq 14,5) = 1,3\%$



Question 4. À l'aide de l'extrait de table de la fonction de répartition de $\chi^2(5)$ ci-dessous, en déduire la p-value, puis conclure aux seuils $\alpha = 5\%$ et $\alpha = 1\%$.

x	9	10	11	12	13	14	14,5	15	16
$F(x) = P(\chi^2(5) \leq x)$	0,891	0,925	0,949	0,965	0,977	0,984	0,987	0,990	0,993

Conclusion: On ne rejette pas H_0 .
 Il s'est passé un événement qui avait 1,3% chance d'arriver mais nous avions fixé un seuil à 1%.

Pour aller plus loin. Le test du χ^2 s'étend (avec quelques modifications) à de nombreux contextes : indépendance entre deux variables (tableau de contingence), homogénéité entre populations, qualité d'ajustement à une loi continue (après regroupement en classes). On pourra y revenir en TD.

4. Dualité intervalle de confiance $\iff$ test

Question 1. Au CM4, on avait construit l'intervalle de confiance à 95% pour μ dans le problème des sacs de ciment : $IC_{95\%} = [24,702; 24,898]$. Cet intervalle contient-il $\mu_0 = 25$?

Question 2. Montrer que les deux énoncés suivants sont **équivalents** :

- (a) On rejette $H_0 : \mu = \mu_0$ au seuil α .
- (b) $\mu_0 \notin IC_{1-\alpha}$ (l'intervalle de confiance à $1 - \alpha$).

Dualité IC / test. Au même seuil α :

$$\text{Rejeter } H_0 : \mu = \mu_0 \iff \mu_0 \notin IC_{1-\alpha}.$$

L'intervalle de confiance est l'**ensemble des valeurs μ_0 qu'on ne rejeterait pas** au seuil α .

Conséquence pratique. Si on a déjà calculé un IC à 95 %, on a *gratuitement* un test bilatéral au seuil 5 % pour n'importe quelle valeur μ_0 .

5. Tests bilatéral et unilatéral

5.1 Définition : trois façons de formuler H_0

Jusqu'ici, on a posé $H_0 : \mu = \mu_0$ contre $H_1 : \mu \neq \mu_0$: *n'importe quel* écart à μ_0 amène à rejeter. Mais selon la question pratique qu'on se pose, on peut vouloir **fixer le sens de l'écart** qu'on cherche à détecter. L'hypothèse H_0 (et son alternative H_1) peut alors prendre trois formes :

- **Test bilatéral** : $H_0 : \mu = \mu_0$ contre $H_1 : \mu \neq \mu_0$.
On suspecte un écart *dans n'importe quel sens*.
- **Test unilatéral à gauche** : $H_0 : \mu \geq \mu_0$ contre $H_1 : \mu < \mu_0$.
On veut seulement détecter un écart *vers le bas* : H_0 couvre toutes les valeurs « acceptables » (μ_0 et au-dessus).
- **Test unilatéral à droite** : $H_0 : \mu \leq \mu_0$ contre $H_1 : \mu > \mu_0$.
On veut seulement détecter un écart *vers le haut*.

Remarque. Pour les calculs, le cas « pire » (le plus défavorable au rejet) sous une H_0 unilatérale est toujours $\mu = \mu_0$ (la frontière). On garde donc la même statistique $Z = (\bar{X} - \mu_0)/(\sigma/\sqrt{n}) \approx \mathcal{N}(0, 1)$; seule la zone de rejet change.

Le contexte dicte le choix. Le sens de H_0 se déduit *toujours* de la situation à analyser, jamais des données observées. Trois exemples :

Plus α est petit, plus c'est difficile de rejeter H_0 .
 6. Deux types d'erreurs Il faut qu'il se passe un événement proba α

Un test n'est **jamais** certain : il peut se tromper de deux façons.

	H_0 vraie en réalité	H_0 fausse en réalité
Décision : <i>garder</i> H_0	✓ bonne décision	erreur de type II (β)
Décision : <i>rejeter</i> H_0	erreur de type I (α)	✓ bonne décision

- **Erreur de type I** : on rejette H_0 alors qu'elle est vraie. Sa probabilité est précisément α (le seuil qu'on fixe).
- **Erreur de type II** : on garde H_0 alors qu'elle est fausse. Sa probabilité β dépend de la vraie valeur du paramètre (et n'est en général *pas* égale à $1 - \alpha$).

Le compromis fondamental.

À n fixé : diminuer $\alpha \implies$ augmenter β . Diminuer les deux à la fois nécessite d'augmenter n .

Analogie au tribunal. H_0 = « l'accusé est innocent ».

- Type I : condamner un innocent. Très grave $\implies$ on prend α *petit*.
- Type II : acquitter un coupable. Moins grave dans la philosophie du droit, mais pas négligeable.

Question — Application industrielle. Une machine produit en moyenne 3 % de boulons défectueux. On prélève chaque jour $n = 200$ boulons. On décide la règle « **rejeter le lot et arrêter la machine si plus de 10 défectueux** ».

1. Sous H_0 (la machine est bien réglée, $p = 0,03$), quelle loi suit le nombre X de défauts dans l'échantillon ? Donner son espérance et son écart-type.
2. Par approximation normale (TCL), calculer le risque de type I, c'est-à-dire la probabilité d'arrêter la machine alors qu'elle est bien réglée.

Et si on durcissait la règle ? Avec « rejet si plus de 14 défauts », α tomberait à environ 0,05 %... mais on laisserait passer beaucoup plus de lots vraiment défectueux (β augmente). C'est le compromis.

7. Bilan

À retenir.

1. **Test d'hypothèse** : on confronte une hypothèse H_0 (modèle de référence) aux données. On rejette H_0 si l'observation est « trop improbable » sous H_0 .
2. **p-value** : $P(\text{observation au moins aussi extrême} \mid H_0)$. On rejette si $p\text{-value} < \alpha$.
3. **Recette d'un test sur la moyenne (σ connu)** : statistique $Z = (\bar{X}_n - \mu_0)/(\sigma/\sqrt{n})$, qui suit $\mathcal{N}(0, 1)$ sous H_0 . Rejet bilatéral si $|Z_{\text{obs}}| > t_\alpha$ ($t_{0,05} = 1,96$); rejet unilatéral si Z_{obs} franchit $\pm u_\alpha$ ($u_{0,05} = 1,645$).
4. **Test du khi-deux d'adéquation** : $\chi^2_{\text{obs}} = \sum (O_i - E_i)^2 / E_i$, distribué $\chi^2(r - 1)$ sous H_0 . Rejet si χ^2_{obs} « trop grand ».
5. **Dualité IC $\Leftrightarrow$ test** : on rejette $H_0 : \mu = \mu_0$ au seuil α si et seulement si $\mu_0 \notin IC_{1-\alpha}$.
6. **Bilatéral vs unilatéral** : choisir d'après le contexte, *avant* l'expérience.
7. **Deux types d'erreurs** : type I (α , fixé) et type II (β , dépend de la vraie valeur). Pour diminuer les deux à la fois : augmenter n .