

Probabilités — CM5

Tests d'hypothèses : à partir de quand être surpris ?

1. Un problème : faut-il être surpris ?

Cadre. Vous êtes au volant sur l'autoroute. Vous savez (statistiques constructeurs) qu'en France, environ 10 % des voitures sont **rouges**. Soudain, vous croisez 4 **voitures rouges de suite**.

*À partir de quand commence-t-on à douter du modèle
« les couleurs des voitures qui passent sont indépendantes,
chacune rouge avec probabilité 0,10 » ?*

Question 1. Sous ce modèle, quelle est la probabilité de croiser 4 voitures rouges *exactement* d'affilée ?

Les couleurs étant indépendantes :

$$P(4 \text{ rouges de suite}) = 0,10^4 = 10^{-4} = 0,0001.$$

C'est environ une chance sur 10 000. *Rare*, mais pas impossible.

Question 2. Et pour 7 voitures rouges d'affilée ?

$$P(7 \text{ rouges de suite}) = 0,10^7 = 10^{-7} = 0,0000001.$$

Une chance sur dix millions. À ce stade, on ne croit *plus* au modèle.

La logique du test d'hypothèse.

1. On part d'une **hypothèse de référence** (ici : indépendance + $p = 0,10$).
2. On observe un résultat.
3. On calcule la probabilité d'observer un résultat « au moins aussi extrême » sous cette hypothèse.
4. Si cette probabilité est **très petite**, on **rejette** l'hypothèse : elle est incompatible avec les données.

Remarque. On ne « prouve » jamais qu'une hypothèse est vraie. On peut seulement décider qu'elle est trop incompatible avec les données pour être maintenue. Comme au tribunal : on rejette la présomption d'innocence (au-delà d'un doute raisonnable) ou bien on l'**accepte par défaut** — ce n'est pas pareil que « prouver que l'accusé est innocent ».

2. Formalisation : hypothèse, p-value, décision

Vocabulaire.

- **Hypothèse nulle** H_0 : l'hypothèse « par défaut » qu'on cherche à mettre à l'épreuve.
- **Hypothèse alternative** H_1 : ce qui reste si H_0 est fausse.
- **Statistique de test** : une quantité calculée sur l'échantillon, dont on connaît la loi *sous* H_0 .
- **p-value** : probabilité, *sous* H_0 , d'observer un résultat au moins aussi extrême que celui qu'on a obtenu.
- **Seuil** α : seuil de tolérance (typiquement 5 % ou 1 %). On rejette H_0 si $p\text{-value} < \alpha$.

Question 1. Dans l'exemple des voitures, quelles sont H_0 et H_1 ? Quelle p-value obtient-on avec 4 rouges d'affilée ? Au seuil $\alpha = 0,05$, rejette-t-on H_0 ?

H_0 : « les couleurs sont indépendantes et $p_{\text{rouge}} = 0,10$ ».

H_1 : « il y a un biais (dépendance ou p plus grand) ».

$p\text{-value} = P(\text{au moins 4 rouges de suite} \mid H_0) = 10^{-4}$.

$10^{-4} < 0,05$, donc on **rejette** H_0 .

Attention. Le seuil α est arbitraire et doit être fixé **avant** l'expérience. Sinon, on est tenté de « l'ajuster » pour faire dire aux données ce qu'on veut. C'est l'origine du célèbre « *p-hacking* » en sciences.

3. Test sur une moyenne

On revient sur l'exemple central du CM4 : une usine remplit des sacs de ciment de poids nominal 25 kg, avec un écart-type de remplissage $\sigma = 0,5$ kg *connu*. Le chef de production veut savoir si la machine est **dérégulée**.

Il pèse $n = 100$ sacs et obtient une moyenne empirique $\bar{X}_n = 24,8$ kg.

Question 1. Quelles sont H_0 et H_1 dans ce problème ?

$H_0 : \mu = 25$ (la machine est bien réglée).

$H_1 : \mu \neq 25$ (la machine est dérégulée).

Question 2. Sous H_0 , donner la loi approximative de $\bar{X}_n$ (TCL).

Sous H_0 , les sacs sont i.i.d. d'espérance 25 et d'écart-type 0,5. Par le TCL,

$$\bar{X}_n \approx \mathcal{N}\left(25, \frac{0,5^2}{100}\right), \quad \text{d'écart-type } \frac{\sigma}{\sqrt{n}} = 0,05.$$

Question 3. Construire la **statistique de test** Z qui suit $\mathcal{N}(0, 1)$ sous H_0 . Calculer la valeur observée Z_{obs} .

On standardise sous H_0 :

$$Z = \frac{\bar{X}_n - 25}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1).$$

Valeur observée :

$$Z_{\text{obs}} = \frac{24,8 - 25}{0,05} = -4.$$


Question 4. L'écart $\bar{X}_n - 25 = -0,2$ est-il « du bon côté » ? Plus précisément, le problème porte sur $\bar{X}_n \neq 25$ (et non $\bar{X}_n < 25$). Quelle est alors la p-value ?

On teste $H_0 : \mu = 25$ contre $H_1 : \mu \neq 25$ (**test bilatéral**). On considère donc les écarts *dans les deux sens* :

$$\text{p-value} = P(|Z| \geq |Z_{\text{obs}}| \mid H_0) = P(|Z| \geq 4) = 2(1 - \Phi(4)).$$

Or $1 - \Phi(4) \approx 3,2 \cdot 10^{-5}$, donc $\text{p-value} \approx 6,4 \cdot 10^{-5}$.

$6,4 \cdot 10^{-5} \ll 0,05$: on **rejette** H_0 . La machine est déréglée.



Recette du test bilatéral sur une moyenne (σ connu).

1. $H_0 : \mu = \mu_0$ contre $H_1 : \mu \neq \mu_0$.
2. Statistique : $Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$, qui suit $\mathcal{N}(0, 1)$ sous H_0 .
3. Seuil α (souvent 0,05) $\Rightarrow$ valeur critique t_α (par exemple $t_{0,05} = 1,96$).
4. **Décision** : rejeter H_0 si $|Z_{\text{obs}}| > t_\alpha$, sinon **ne pas rejeter**.

4. Dualité intervalle de confiance $\iff$ test

Question 1. Au CM4, on avait construit l'intervalle de confiance à 95 % pour μ dans le problème des sacs de ciment : $IC_{95\%} = [24,702 ; 24,898]$. Cet intervalle contient-il $\mu_0 = 25$?

Non. La valeur 25 est en dehors. C'est exactement la même conclusion que le test : la machine est déréglée.

Question 2. Montrer que les deux énoncés suivants sont **équivalents** :

- (a) On rejette $H_0 : \mu = \mu_0$ au seuil α .
- (b) $\mu_0 \notin IC_{1-\alpha}$ (l'intervalle de confiance à $1 - \alpha$).

$$\text{On a rejet} \iff |Z_{\text{obs}}| > t_\alpha \iff |\bar{X}_n - \mu_0| > t_\alpha \frac{\sigma}{\sqrt{n}} \iff \mu_0 \notin \left[\bar{X}_n - t_\alpha \frac{\sigma}{\sqrt{n}} ; \bar{X}_n + t_\alpha \frac{\sigma}{\sqrt{n}} \right] \iff \mu_0 \notin IC_{1-\alpha}.$$

C'est exactement le même calcul, vu sous deux angles.

Dualité IC / test. Au même seuil α :

$$\text{Rejeter } H_0 : \mu = \mu_0 \iff \mu_0 \notin IC_{1-\alpha}.$$

L'intervalle de confiance est l'**ensemble des valeurs μ_0 qu'on ne rejetterait pas** au seuil α .

Conséquence pratique. Si on a déjà calculé un IC à 95 %, on a *gratuitement* un test bilatéral au seuil 5 % pour n'importe quelle valeur μ_0 .

5. Tests bilatéral et unilatéral

5.1. Le contexte change l'hypothèse alternative

Considérons deux situations à statistique de test identique :

- **Sacs de ciment.** La machine peut être dérégulée *vers le haut* (perte de matière première) *ou vers le bas* (sacs sous-remplis, fraude). On veut détecter tout dérèglement : $H_1 : \mu \neq 25$. **Bilatéral.**
- **Ampoules du vendeur.** Le vendeur prétend $\mu_0 = 1000$ h. Si la durée moyenne réelle est *supérieure* (les ampoules durent plus que prévu), c'est tout bénéfice : on n'a aucune raison de s'en plaindre. On ne suspecte que le dérapage *vers le bas* : $H_1 : \mu < 1000$. **Unilatéral à gauche.**

5.2. Conséquence sur la valeur critique

Question 1. Au CM4, sur les ampoules ($n = 50$, $\sigma = 100$, $\bar{X}_n = 950$), on a calculé $Z_{\text{obs}} = (950 - 1000)/(100/\sqrt{50}) = -3,53$. Calculer la p-value **unilatérale** (test « les ampoules durent moins »).

$$\text{p-value} = P(Z \leq -3,53 \mid H_0) = \Phi(-3,53) \approx 2,1 \cdot 10^{-4}.$$

Très petite : on rejette H_0 . Le vendeur ment.

Question 2. Si on avait fait un test bilatéral, quelle aurait été la p-value ?


$$\text{p-value}_{\text{bilat}} = 2 \cdot \Phi(-3,53) \approx 4,2 \cdot 10^{-4}.$$

Deux fois plus grande, mais on rejette toujours.

À retenir.

- **Bilatéral** ($H_1 : \mu \neq \mu_0$) : on coupe α en deux, rejet si $|Z_{\text{obs}}| > t_\alpha$ avec $t_{0,05} = 1,96$.
- **Unilatéral à gauche** ($H_1 : \mu < \mu_0$) : tout α à gauche, rejet si $Z_{\text{obs}} < -u_\alpha$ avec $u_{0,05} = 1,645$.
- **Unilatéral à droite** ($H_1 : \mu > \mu_0$) : tout α à droite, rejet si $Z_{\text{obs}} > u_\alpha$.

Important. Le choix « bilatéral / unilatéral » se fait **avant** de regarder les données, en fonction du *contexte du problème*, jamais pour faire arranger la p-value.



5.3. Application : durée de vie d'une élingue de levage

Cadre. Une entreprise de BTP commande des **élingues d'acier** pour ses chantiers de levage. Le fabricant annonce une durée de vie moyenne avant rupture de $\mu_0 = 5000$ heures de service. La durée de vie d'une élingue est modélisée par une loi **exponentielle** de paramètre λ (sans mémoire : si elle a tenu t heures, sa durée de vie future a même loi qu'au début).

Sur un échantillon de $n = 50$ élingues testées jusqu'à la rupture, on observe une durée moyenne empirique $\bar{X}_n = 4200$ heures.

Question 1. Pour une loi exponentielle $\mathcal{E}(\lambda)$, rappeler $\mathbb{E}(X)$ et $\sigma(X)$ en fonction de λ . En déduire une propriété remarquable reliant σ et μ .

$\mathbb{E}(X) = 1/\lambda$ et $\text{Var}(X) = 1/\lambda^2$, donc $\sigma(X) = 1/\lambda$. On en déduit la **propriété remarquable** de la loi exponentielle :

$$\sigma = \mu.$$

Connaître la moyenne suffit à connaître l'écart-type — très pratique pour les tests.

Question 2. Justifier que le test à mener est *unilatéral* et formuler H_0 et H_1 .

Le fabricant aurait intérêt à *surestimer* la durée de vie (argument commercial). On ne suspecte que le dérapage vers le bas :

$$H_0 : \mu = 5000 \quad \text{contre} \quad H_1 : \mu < 5000.$$

Unilatéral à gauche.

Question 3. Quelle loi suit approximativement $\bar{X}_n$ sous H_0 ? Construire la statistique de test et calculer Z_{obs} .

Sous H_0 , $\mu = 5000$ donc $\sigma = 5000$ (propriété de l'exponentielle). Par le TCL :

$$\bar{X}_n \approx \mathcal{N}\left(5000, \frac{5000^2}{50}\right), \quad Z = \frac{\bar{X}_n - 5000}{5000/\sqrt{50}} \approx \mathcal{N}(0, 1).$$

$$Z_{\text{obs}} = \frac{4200 - 5000}{5000/\sqrt{50}} = \frac{-800}{707,1} \approx -1,13.$$

Question 4. Calculer la p-value et conclure au seuil 5 %.

Test unilatéral à gauche :

$$\text{p-value} = P(Z \leq -1,13 \mid H_0) = \Phi(-1,13) = 1 - \Phi(1,13) \approx 0,129.$$

$0,129 > 0,05$: on **ne rejette pas** H_0 . L'écart de 800 h observé est compatible avec une simple fluctuation d'échantillonnage.

Moralité — attention au piège. « Ne pas rejeter H_0 » ne veut pas dire « prouver que H_0 est vraie ». Cela veut dire : « les données ne suffisent pas à prouver le contraire ». Pour trancher, soit on augmente la taille de l'échantillon, soit on accepte de rester sur l'annonce du fabricant par défaut. Si l'enjeu de sécurité est lourd (rupture d'une élingue $\implies$ chute de charge), on peut préférer un seuil α *plus grand* (10 % par exemple) pour rejeter plus facilement.

6. Deux types d'erreurs

Un test n'est **jamais** certain : il peut se tromper de deux façons.

	H_0 vraie en réalité	H_0 fausse en réalité
Décision : <i>garder</i> H_0	✓ bonne décision	erreur de type II (β)
Décision : <i>rejeter</i> H_0	erreur de type I (α)	✓ bonne décision

- **Erreur de type I** : on rejette H_0 alors qu'elle est vraie. Sa probabilité est précisément α (le seuil qu'on fixe).
- **Erreur de type II** : on garde H_0 alors qu'elle est fausse. Sa probabilité β dépend de la vraie valeur du paramètre (et n'est en général *pas* égale à $1 - \alpha$).

Le compromis fondamental.

À n fixé : diminuer $\alpha \implies$ augmenter β . Diminuer les deux à la fois nécessite d'augmenter n .

Analogie au tribunal. H_0 = « l'accusé est innocent ».

- Type I : condamner un innocent. Très grave $\implies$ on prend α *petit*.
- Type II : acquitter un coupable. Moins grave dans la philosophie du droit, mais pas négligeable.

Question — Application industrielle. Une machine produit en moyenne 3 % de boulons défectueux. On prélève chaque jour $n = 200$ boulons. On décide la règle « **rejeter le lot et arrêter la machine si plus de 10 défectueux** ».

1. Sous H_0 (la machine est bien réglée, $p = 0,03$), quelle loi suit le nombre X de défauts dans l'échantillon ? Donner son espérance et son écart-type.
2. Par approximation normale (TCL), calculer le risque de type I, c'est-à-dire la probabilité d'arrêter la machine alors qu'elle est bien réglée.

1. $X \sim \mathcal{B}(200, 0,03)$, donc

$$\mathbb{E}(X) = np = 6, \quad \sigma(X) = \sqrt{np(1-p)} = \sqrt{200 \cdot 0,03 \cdot 0,97} \approx 2,41.$$

2. Par le TCL, sous H_0 , $X \approx \mathcal{N}(6, 2,41^2)$.

$$P(X > 10 \mid H_0) = P\left(Z > \frac{10-6}{2,41}\right) = P(Z > 1,66) \approx 1 - \Phi(1,66) \approx 0,049.$$

Soit environ 5 % : c'est notre seuil α . Une fois tous les vingt jours environ, on arrêtera la machine à tort.

Et si on durcissait la règle ? Avec « rejet si plus de 14 défauts », α tomberait à environ 0,05 %... mais on laisserait passer beaucoup plus de lots vraiment défectueux (β augmente). C'est le compromis.

7. Vers les estimateurs : préparer le CM6

Tous nos tests ont supposé jusqu'ici que σ (ou p) était **connu**. Et si on ne connaissait *rien* de la loi des données — juste l'échantillon ?

La question. Étant donné un échantillon $X_1, \dots, X_n$ supposé issu d'une loi *paramétrique* (binomiale, exponentielle, normale...), comment **deviner** le paramètre ?

Idée centrale : la méthode des moments. Pour une loi paramétrée par θ , l'espérance théorique $\mathbb{E}(X)$ s'exprime en fonction de θ . On **remplace l'espérance par la moyenne empirique** :

$$\mathbb{E}(X) = g(\theta) \xrightarrow{\text{remplace}} \bar{X}_n = g(\hat{\theta}) \implies \hat{\theta} = g^{-1}(\bar{X}_n).$$

Question 1. Soit $X_1, \dots, X_n$ i.i.d. de loi exponentielle $\mathcal{E}(\lambda)$. Donner $\mathbb{E}(X)$, puis déduire un estimateur $\hat{\lambda}$ par la méthode des moments.

$\mathbb{E}(X) = 1/\lambda$, donc en posant $\bar{X}_n = 1/\hat{\lambda}$, on obtient

$$\hat{\lambda} = \frac{1}{\bar{X}_n}.$$

On retrouve l'estimateur du CM4 (durée des appels). Si la durée moyenne empirique est de 5 min, on estime $\lambda = 0,2$ appel/min.

Question 2. Soit $X_1, \dots, X_n$ i.i.d. de loi de Bernoulli $\mathcal{B}(p)$ ($X_i \in \{0, 1\}$). Estimer p .

$\mathbb{E}(X) = p$, donc $\hat{p} = \bar{X}_n$. C'est la **proportion observée** : on retrouve l'estimateur déjà utilisé en CM3 (sondages) et CM4.

Question 3. Soit $X_1, \dots, X_n$ i.i.d. de loi de Poisson $\mathcal{P}(\lambda)$. Estimer λ .

$\mathbb{E}(X) = \lambda$, donc $\hat{\lambda} = \bar{X}_n$. Pour la Poisson, le paramètre est l'espérance.

7.1. Application : centre d'appels

Un centre d'appels modélise la durée d'un appel par une loi exponentielle $\mathcal{E}(\lambda)$. Sur $n = 100$ appels, on observe une durée moyenne empirique $\bar{X}_n = 4$ minutes.

Question 1. Donner l'estimation ponctuelle $\hat{\lambda}$.

$$\hat{\lambda} = 1/\bar{X}_n = 1/4 = 0,25 \text{ appel/minute.}$$

Question 2. Construire un IC à 95 % pour $\mu = 1/\lambda$. On utilisera la propriété $\sigma = \mu$ de l'exponentielle et le plug-in $\hat{\sigma} = \bar{X}_n$ (puisque σ n'est pas connu, on l'estime par la même valeur).

La demi-largeur de l'IC est $1,96 \frac{\hat{\sigma}}{\sqrt{n}} = 1,96 \frac{4}{\sqrt{100}} = 0,784$. D'où

$$IC_{95\%}(\mu) = [4 - 0,784; 4 + 0,784] = [3,22; 4,78] \text{ min.}$$

Question 3. En déduire un IC à 95 % pour λ . (Indice : $\lambda \mapsto 1/\lambda$ est décroissante, donc inverser les bornes et les permuter.)

$$IC_{95\%}(\lambda) = \left[\frac{1}{4,78}; \frac{1}{3,22} \right] \approx [0,21; 0,31] \text{ appel/min.}$$

7.2. Application : fiabilité d'une pompe de chantier

Une pompe de chantier subit une panne au bout d'un temps modélisé par une loi exponentielle $\mathcal{E}(\lambda)$ (propriété sans mémoire : l'usure n'est pas prise en compte). Le service maintenance relève les durées avant panne de $n = 30$ pompes : moyenne empirique $\bar{X}_n = 850$ heures.

Question 1. Estimer μ et λ .

$$\hat{\mu} = \bar{X}_n = 850 \text{ h}; \quad \hat{\lambda} = 1/850 \approx 1,18 \cdot 10^{-3} \text{ /h.}$$

Question 2. Le fabricant annonce une durée de vie moyenne de $\mu_0 = 1000$ h. Tester cette annonce contre l'hypothèse « les pompes durent moins » au seuil 5 %.

Test unilatéral à gauche : $H_0 : \mu = 1000$, $H_1 : \mu < 1000$. Sous H_0 , $\sigma = 1000$ (expo) :

$$Z_{\text{obs}} = \frac{850 - 1000}{1000/\sqrt{30}} = \frac{-150}{182,6} \approx -0,82.$$

$$\text{p-value} = \Phi(-0,82) \approx 1 - 0,794 = 0,206.$$

$0,206 > 0,05$: on **ne rejette pas**. L'annonce du fabricant reste plausible.

Question 3. En utilisant l'estimation $\hat{\lambda}$, calculer la probabilité qu'une nouvelle pompe fonctionne plus de 1500 heures sans panne.

Pour une exponentielle de paramètre λ : $P(X > t) = e^{-\lambda t}$. D'où

$$P(X > 1500) \approx e^{-1500/850} = e^{-1,765} \approx 0,171.$$

Environ 17 % des pompes dépassent 1500 heures.

Question 4 — Bonus. Le chef de chantier veut être sûr à 90 % qu'une pompe tiendra au moins T heures. Quelle valeur prendre pour T ?

On cherche T tel que $P(X > T) = 0,90$, soit $e^{-\hat{\lambda}T} = 0,90$:

$$T = -\frac{\ln 0,90}{\hat{\lambda}} = 850 \cdot \ln(10/9) \approx 850 \cdot 0,105 \approx 90 \text{ heures.}$$

Sous nos hypothèses, on n'a que 90 heures de « garantie » à 90 %. La loi exponentielle est très *prudente* : elle suppose que la pompe peut tomber en panne à tout instant.

Au CM6 et au TD5, on formalisera ce que « bien estimer » veut dire (**biais**, **variance** d'un estimateur), et on construira des estimateurs par d'autres méthodes (moments d'ordre 2, maximum de vraisemblance pour les motivés).

8. Bilan

À retenir.

1. **Test d'hypothèse** : on confronte une hypothèse H_0 (modèle de référence) aux données. On rejette H_0 si l'observation est « trop improbable » sous H_0 .
2. **p-value** : $P(\text{observation au moins aussi extrême} \mid H_0)$. On rejette si $p\text{-value} < \alpha$.
3. **Recette test bilatéral sur la moyenne (σ connu)** : statistique $Z = (\bar{X}_n - \mu_0)/(\sigma/\sqrt{n})$, qui suit $\mathcal{N}(0, 1)$ sous H_0 . Rejet si $|Z_{\text{obs}}| > t_\alpha$ ($t_{0,05} = 1,96$).
4. **Dualité IC $\Leftrightarrow$ test** : on rejette $H_0 : \mu = \mu_0$ au seuil α si et seulement si $\mu_0 \notin IC_{1-\alpha}$.
5. **Bilatéral vs unilatéral** : choisir d'après le contexte, *avant* l'expérience.
6. **Deux types d'erreurs** : type I (α , fixé) et type II (β , dépend de la vraie valeur). Pour diminuer les deux à la fois : augmenter n .
7. **Méthode des moments** : pour estimer un paramètre θ , exprimer $\mathbb{E}(X) = g(\theta)$, puis poser $\bar{X}_n = g(\hat{\theta})$ et résoudre.