

Probabilités — CM5

Tests d'hypothèses : à partir de quand être surpris ?

1. Un problème : faut-il être surpris ?

Cadre. Vous êtes au volant sur l'autoroute. Vous savez (statistiques constructeurs) qu'en France, environ 10 % des voitures sont **rouges**. Soudain, vous croisez 4 **voitures rouges de suite**.

*À partir de quand commence-t-on à douter du modèle
« les couleurs des voitures qui passent sont indépendantes,
chacune rouge avec probabilité 0,10 » ?*

Question 1. Sous ce modèle, quelle est la probabilité de croiser 4 voitures rouges *exactement* d'affilée ?

Les couleurs étant indépendantes :

$$P(4 \text{ rouges de suite}) = 0,10^4 = 10^{-4} = 0,0001.$$

C'est environ une chance sur 10 000. *Rare*, mais pas impossible.

Question 2. Et pour 7 voitures rouges d'affilée ?

$$P(7 \text{ rouges de suite}) = 0,10^7 = 10^{-7} = 0,0000001.$$

Une chance sur dix millions. À ce stade, on ne croit *plus* au modèle.

La logique du test d'hypothèse.

1. On part d'une **hypothèse de référence** (ici : indépendance + $p = 0,10$).
2. On observe un résultat.
3. On calcule la probabilité d'observer un résultat « au moins aussi extrême » sous cette hypothèse.
4. Si cette probabilité est **très petite**, on **rejette** l'hypothèse : elle est incompatible avec les données.

Remarque. On ne « prouve » jamais qu'une hypothèse est vraie. On peut seulement décider qu'elle est trop incompatible avec les données pour être maintenue. Comme au tribunal : on rejette la présomption d'innocence (au-delà d'un doute raisonnable) ou bien on l'**accepte par défaut** — ce n'est pas pareil que « prouver que l'accusé est innocent ».

2. Formalisation : hypothèse, p-value, décision

Vocabulaire.

- **Hypothèse nulle** H_0 : l'hypothèse « par défaut » qu'on cherche à mettre à l'épreuve.
- **Hypothèse alternative** H_1 : ce qui reste si H_0 est fausse.
- **Statistique de test** : une quantité calculée sur l'échantillon, dont on connaît la loi *sous* H_0 .
- **p-value** : probabilité, *sous* H_0 , d'observer un résultat au moins aussi extrême que celui qu'on a obtenu.
- **Seuil** α : seuil de tolérance (typiquement 5 % ou 1 %). On rejette H_0 si $p\text{-value} < \alpha$.

Question 1. Dans l'exemple des voitures, quelles sont H_0 et H_1 ? Quelle p-value obtient-on avec 4 rouges d'affilée ? Au seuil $\alpha = 0,05$, rejette-t-on H_0 ?

H_0 : « les couleurs sont indépendantes et $p_{\text{rouge}} = 0,10$ ».

H_1 : « il y a un biais (dépendance ou p plus grand) ».

$p\text{-value} = P(\text{au moins 4 rouges de suite} \mid H_0) = 10^{-4}$.

$10^{-4} < 0,05$, donc on **rejette** H_0 .

Attention. Le seuil α est arbitraire et doit être fixé **avant** l'expérience. Sinon, on est tenté de « l'ajuster » pour faire dire aux données ce qu'on veut. C'est l'origine du célèbre « *p*-hacking » en sciences.

3. Test sur une moyenne

On revient sur l'exemple central du CM4 : une usine remplit des sacs de ciment de poids nominal 25 kg, avec un écart-type de remplissage $\sigma = 0,5$ kg *connu*. Le chef de production veut savoir si la machine est **dérégulée**.

Il pèse $n = 100$ sacs et obtient une moyenne empirique $\bar{X}_n = 24,8$ kg.

Question 1. Quelles sont H_0 et H_1 dans ce problème ?

$H_0 : \mu = 25$ (la machine est bien réglée).

$H_1 : \mu \neq 25$ (la machine est dérégulée).

Question 2. Sous H_0 , donner la loi approximative de $\bar{X}_n$ (TCL).

Sous H_0 , les sacs sont i.i.d. d'espérance 25 et d'écart-type 0,5. Par le TCL,

$$\bar{X}_n \approx \mathcal{N}\left(25, \frac{0,5^2}{100}\right), \quad \text{d'écart-type } \frac{\sigma}{\sqrt{n}} = 0,05.$$

Question 3. Construire la **statistique de test** Z qui suit $\mathcal{N}(0, 1)$ sous H_0 . Calculer la valeur observée Z_{obs} .

On standardise sous H_0 :

$$Z = \frac{\bar{X}_n - 25}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1).$$

Valeur observée :

$$Z_{\text{obs}} = \frac{24,8 - 25}{0,05} = -4.$$


Question 4. L'écart $\bar{X}_n - 25 = -0,2$ est-il « du bon côté » ? Plus précisément, le problème porte sur $\bar{X}_n \neq 25$ (et non $\bar{X}_n < 25$). Quelle est alors la p-value ?

On teste $H_0 : \mu = 25$ contre $H_1 : \mu \neq 25$ (**test bilatéral**). On considère donc les écarts *dans les deux sens* :

$$\text{p-value} = P(|Z| \geq |Z_{\text{obs}}| \mid H_0) = P(|Z| \geq 4) = 2(1 - \Phi(4)).$$

Or $1 - \Phi(4) \approx 3,2 \cdot 10^{-5}$, donc $\text{p-value} \approx 6,4 \cdot 10^{-5}$.

$6,4 \cdot 10^{-5} \ll 0,05$: on **rejette** H_0 . La machine est déréglée.



Recette du test bilatéral sur une moyenne (σ connu).

1. $H_0 : \mu = \mu_0$ contre $H_1 : \mu \neq \mu_0$.
2. Statistique : $Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$, qui suit $\mathcal{N}(0, 1)$ sous H_0 .
3. Seuil α (souvent 0,05) $\Rightarrow$ valeur critique t_α (par exemple $t_{0,05} = 1,96$).
4. **Décision** : rejeter H_0 si $|Z_{\text{obs}}| > t_\alpha$, sinon **ne pas rejeter**.

4. Dualité intervalle de confiance $\iff$ test

Question 1. Au CM4, on avait construit l'intervalle de confiance à 95 % pour μ dans le problème des sacs de ciment : $IC_{95\%} = [24,702 ; 24,898]$. Cet intervalle contient-il $\mu_0 = 25$?

Non. La valeur 25 est en dehors. C'est exactement la même conclusion que le test : la machine est déréglée.

Question 2. Montrer que les deux énoncés suivants sont **équivalents** :

- (a) On rejette $H_0 : \mu = \mu_0$ au seuil α .
- (b) $\mu_0 \notin IC_{1-\alpha}$ (l'intervalle de confiance à $1 - \alpha$).

$$\text{On a rejet} \iff |Z_{\text{obs}}| > t_\alpha \iff |\bar{X}_n - \mu_0| > t_\alpha \frac{\sigma}{\sqrt{n}} \iff \mu_0 \notin \left[\bar{X}_n - t_\alpha \frac{\sigma}{\sqrt{n}} ; \bar{X}_n + t_\alpha \frac{\sigma}{\sqrt{n}} \right] \iff \mu_0 \notin IC_{1-\alpha}.$$

C'est exactement le même calcul, vu sous deux angles.

Dualité IC / test. Au même seuil α :

$$\text{Rejeter } H_0 : \mu = \mu_0 \iff \mu_0 \notin IC_{1-\alpha}.$$

L'intervalle de confiance est l'**ensemble des valeurs μ_0 qu'on ne rejetterait pas** au seuil α .

Conséquence pratique. Si on a déjà calculé un IC à 95 %, on a *gratuitement* un test bilatéral au seuil 5 % pour n'importe quelle valeur μ_0 .

5. Tests bilatéral et unilatéral

5.1. Le contexte change l'hypothèse alternative

Considérons deux situations à statistique de test identique :

- **Sacs de ciment.** La machine peut être dérégulée *vers le haut* (perte de matière première) *ou vers le bas* (sacs sous-remplis, fraude). On veut détecter tout dérèglement : $H_1 : \mu \neq 25$. **Bilatéral.**
- **Ampoules du vendeur.** Le vendeur prétend $\mu_0 = 1000$ h. Si la durée moyenne réelle est *supérieure* (les ampoules durent plus que prévu), c'est tout bénéfice : on n'a aucune raison de s'en plaindre. On ne suspecte que le dérapage *vers le bas* : $H_1 : \mu < 1000$. **Unilatéral à gauche.**

5.2. Conséquence sur la valeur critique

Question 1. Au CM4, sur les ampoules ($n = 50$, $\sigma = 100$, $\bar{X}_n = 950$), on a calculé $Z_{\text{obs}} = (950 - 1000)/(100/\sqrt{50}) = -3,53$. Calculer la p-value **unilatérale** (test « les ampoules durent moins »).

$$\text{p-value} = P(Z \leq -3,53 \mid H_0) = \Phi(-3,53) \approx 2,1 \cdot 10^{-4}.$$

Très petite : on rejette H_0 . Le vendeur ment.

Question 2. Si on avait fait un test bilatéral, quelle aurait été la p-value ?


$$\text{p-value}_{\text{bilat}} = 2 \cdot \Phi(-3,53) \approx 4,2 \cdot 10^{-4}.$$

Deux fois plus grande, mais on rejette toujours.

À retenir.

- **Bilatéral** ($H_1 : \mu \neq \mu_0$) : on coupe α en deux, rejet si $|Z_{\text{obs}}| > t_\alpha$ avec $t_{0,05} = 1,96$.
- **Unilatéral à gauche** ($H_1 : \mu < \mu_0$) : tout α à gauche, rejet si $Z_{\text{obs}} < -u_\alpha$ avec $u_{0,05} = 1,645$.
- **Unilatéral à droite** ($H_1 : \mu > \mu_0$) : tout α à droite, rejet si $Z_{\text{obs}} > u_\alpha$.

Important. Le choix « bilatéral / unilatéral » se fait **avant** de regarder les données, en fonction du *contexte du problème*, jamais pour faire arranger la p-value.



6. Deux types d'erreurs

Un test n'est **jamais** certain : il peut se tromper de deux façons.

	H_0 vraie en réalité	H_0 fausse en réalité
Décision : <i>garder</i> H_0	✓ bonne décision	erreur de type II (β)
Décision : <i>rejeter</i> H_0	erreur de type I (α)	✓ bonne décision

- **Erreur de type I** : on rejette H_0 alors qu'elle est vraie. Sa probabilité est précisément α (le seuil qu'on fixe).
- **Erreur de type II** : on garde H_0 alors qu'elle est fausse. Sa probabilité β dépend de la vraie valeur du paramètre (et n'est en général *pas* égale à $1 - \alpha$).

Le compromis fondamental.

À n fixé : diminuer $\alpha \implies$ augmenter β . Diminuer les deux à la fois nécessite d'augmenter n .

Analogie au tribunal. H_0 = « l'accusé est innocent ».

- Type I : condamner un innocent. Très grave $\implies$ on prend α *petit*.
- Type II : acquitter un coupable. Moins grave dans la philosophie du droit, mais pas négligeable.

Question — Application industrielle. Une machine produit en moyenne 3% de boulons défectueux. On prélève chaque jour $n = 200$ boulons. On décide la règle « **rejeter le lot et arrêter la machine si plus de 10 défectueux** ».

1. Sous H_0 (la machine est bien réglée, $p = 0,03$), quelle loi suit le nombre X de défauts dans l'échantillon ? Donner son espérance et son écart-type.
2. Par approximation normale (TCL), calculer le risque de type I, c'est-à-dire la probabilité d'arrêter la machine alors qu'elle est bien réglée.

1. $X \sim \mathcal{B}(200, 0,03)$, donc

$$\mathbb{E}(X) = np = 6, \quad \sigma(X) = \sqrt{np(1-p)} = \sqrt{200 \cdot 0,03 \cdot 0,97} \approx 2,41.$$

2. Par le TCL, sous H_0 , $X \approx \mathcal{N}(6, 2,41^2)$.

$$P(X > 10 \mid H_0) = P\left(Z > \frac{10-6}{2,41}\right) = P(Z > 1,66) \approx 1 - \Phi(1,66) \approx 0,049.$$

Soit environ 5% : c'est notre seuil α . Une fois tous les vingt jours environ, on arrêtera la machine *à tort*.

Et si on durcissait la règle ? Avec « rejet si plus de 14 défauts », α tomberait à environ 0,05 %... mais on laisserait passer beaucoup plus de lots vraiment défectueux (β augmente). C'est le compromis.

7. Vers les estimateurs : préparer le CM6

Tous nos tests ont supposé jusqu'ici que σ (ou p) était **connu**. Et si on ne connaissait *rien* de la loi des données — juste l'échantillon ?

La question. Étant donné un échantillon $X_1, \dots, X_n$ supposé issu d'une loi *paramétrique* (binomiale, exponentielle, normale...), comment **deviner** le paramètre ?

Idée centrale : la méthode des moments. Pour une loi paramétrée par θ , l'espérance théorique $\mathbb{E}(X)$ s'exprime en fonction de θ . On **remplace l'espérance par la moyenne empirique** :

$$\mathbb{E}(X) = g(\theta) \xrightarrow{\text{remplace}} \bar{X}_n = g(\hat{\theta}) \implies \hat{\theta} = g^{-1}(\bar{X}_n).$$

Question 1. Soit $X_1, \dots, X_n$ i.i.d. de loi exponentielle $\mathcal{E}(\lambda)$. Donner $\mathbb{E}(X)$, puis déduire un estimateur $\hat{\lambda}$ par la méthode des moments.

$\mathbb{E}(X) = 1/\lambda$, donc en posant $\bar{X}_n = 1/\hat{\lambda}$, on obtient

$$\hat{\lambda} = \frac{1}{\bar{X}_n}.$$

On retrouve l'estimateur du CM4 (durée des appels). Si la durée moyenne empirique est de 5 min, on estime $\lambda = 0,2$ appel/min.

Question 2. Soit $X_1, \dots, X_n$ i.i.d. de loi de Bernoulli $\mathcal{B}(p)$ ($X_i \in \{0, 1\}$). Estimer p .

$\mathbb{E}(X) = p$, donc $\hat{p} = \bar{X}_n$. C'est la **proportion observée** : on retrouve l'estimateur déjà utilisé en CM3 (sondages) et CM4.

Question 3. Soit $X_1, \dots, X_n$ i.i.d. de loi de Poisson $\mathcal{P}(\lambda)$. Estimer λ .

$\mathbb{E}(X) = \lambda$, donc $\hat{\lambda} = \bar{X}_n$. Pour la Poisson, le paramètre est l'espérance.

Au CM6 et au TD5, on formalisera ce que « bien estimer » veut dire (**biais, variance** d'un estimateur), et on construira des estimateurs par d'autres méthodes (moments d'ordre 2, maximum de vraisemblance pour les motivés).

8. Bilan

À retenir.

1. **Test d'hypothèse** : on confronte une hypothèse H_0 (modèle de référence) aux données. On rejette H_0 si l'observation est « trop improbable » sous H_0 .
2. **p-value** : $P(\text{observation au moins aussi extrême} \mid H_0)$. On rejette si $p\text{-value} < \alpha$.
3. **Recette test bilatéral sur la moyenne (σ connu)** : statistique $Z = (\bar{X}_n - \mu_0)/(\sigma/\sqrt{n})$, qui suit $\mathcal{N}(0, 1)$ sous H_0 . Rejet si $|Z_{\text{obs}}| > t_\alpha$ ($t_{0,05} = 1,96$).
4. **Dualité IC $\Leftrightarrow$ test** : on rejette $H_0 : \mu = \mu_0$ au seuil α si et seulement si $\mu_0 \notin IC_{1-\alpha}$.
5. **Bilatéral vs unilatéral** : choisir d'après le contexte, *avant* l'expérience.
6. **Deux types d'erreurs** : type I (α , fixé) et type II (β , dépend de la vraie valeur). Pour diminuer les deux à la fois : augmenter n .
7. **Méthode des moments** : pour estimer un paramètre θ , exprimer $\mathbb{E}(X) = g(\theta)$, puis poser $\bar{X}_n = g(\hat{\theta})$ et résoudre.