

Probabilités — CM5

Tests d'hypothèses : à partir de quand être surpris ?

1. Un problème : faut-il être surpris ?

Cadre. Vous êtes au volant sur l'autoroute. Vous savez (statistiques constructeurs) qu'en France, environ 10 % des voitures sont **rouges**. Soudain, vous croisez 4 **voitures rouges de suite**.

*À partir de quand commence-t-on à douter du modèle
« les couleurs des voitures qui passent sont indépendantes,
chacune rouge avec probabilité 0,10 » ?*

Question 1. Sous ce modèle, quelle est la probabilité de croiser 4 voitures rouges *exactement* d'affilée ?

Les couleurs étant indépendantes :

$$P(4 \text{ rouges de suite}) = 0,10^4 = 10^{-4} = 0,0001.$$

C'est environ une chance sur 10 000. *Rare*, mais pas impossible.

Question 2. Et pour 7 voitures rouges d'affilée ?

$$P(7 \text{ rouges de suite}) = 0,10^7 = 10^{-7} = 0,0000001.$$

Une chance sur dix millions. À ce stade, on ne croit *plus* au modèle.

La logique du test d'hypothèse — en quatre temps.

1. **Hypothèse de référence** (H_0). On pose un modèle « par défaut » dont on veut éprouver la crédibilité (ici : indépendance + $p = 0,10$).
2. **Observation**. On collecte des données (ici : 4 rouges de suite).
3. **Probabilité sous** H_0 . On calcule la probabilité, *en supposant* H_0 *vraie*, d'observer un résultat « au moins aussi extrême » que celui constaté. C'est la **p-value**.
4. **Décision**. Si cette probabilité est *très petite* (sous un seuil α fixé à l'avance), on **rejette** H_0 : les données sont incompatibles avec le modèle. Sinon, on *conserve* H_0 par défaut.

Remarque. On ne « prouve » jamais qu'une hypothèse est vraie. On peut seulement décider qu'elle est trop incompatible avec les données pour être maintenue. Comme au tribunal : on rejette la présomption d'innocence (au-delà d'un doute raisonnable) ou bien on l'**accepte par défaut** — ce n'est pas pareil que « prouver que l'accusé est innocent ».

1.1. Deuxième exemple : un dé sans aucun 6

On lance un dé à 6 faces 20 fois de suite et, à notre grande surprise, on n'obtient **aucun** 6. Doit-on suspecter que le dé est truqué ?

Question 1. Énoncer l'hypothèse H_0 (« le dé n'est pas truqué ») et proposer une statistique de test naturelle. Quelle est sa loi sous H_0 ?

H_0 : « le dé est équilibré », c'est-à-dire $P(\text{face } 6) = 1/6$ et lancers indépendants.

Statistique naturelle : X = nombre de 6 obtenus en 20 lancers. Sous H_0 ,

$$X \sim \mathcal{B}(20, \frac{1}{6}), \quad \mathbb{E}(X) = \frac{20}{6} \approx 3,33.$$

Question 2. On observe $X_{\text{obs}} = 0$. Calculer la p-value et conclure au seuil $\alpha = 5\%$.

On observe une valeur *anormalement basse* ; la p-value est la probabilité d'observer aussi peu de 6 que cela sous H_0 :

$$\text{p-value} = P(X \leq 0 \mid H_0) = P(X = 0) = \left(\frac{5}{6}\right)^{20} \approx 0,026.$$

$0,026 < 0,05$: on **rejette** H_0 . Le dé semble truqué (manque de 6).

Anecdote. Au seuil $\alpha = 1\%$, on ne rejeterait *pas* : la conclusion dépend du seuil choisi — d'où l'importance de le fixer avant l'expérience.

2. Formalisation : hypothèse, p-value, décision

Vocabulaire.

- **Hypothèse nulle** H_0 : l'hypothèse « par défaut » qu'on cherche à mettre à l'épreuve.
- **Hypothèse alternative** H_1 : ce qui reste si H_0 est fausse.
- **Statistique de test** : une quantité calculée sur l'échantillon, dont on connaît la loi *sous* H_0 .
- **p-value** : probabilité, *sous* H_0 , d'observer un résultat au moins aussi extrême que celui qu'on a obtenu.
- **Seuil** α : seuil de tolérance (typiquement 5% ou 1%). On rejette H_0 si $\text{p-value} < \alpha$.

Question 1. Dans l'exemple des voitures, quelles sont H_0 et H_1 ? Quelle p-value obtient-on avec 4 rouges d'affilée ? Au seuil $\alpha = 0,05$, rejette-t-on H_0 ?

H_0 : « les couleurs sont indépendantes et $p_{\text{rouge}} = 0,10$ ».

H_1 : « il y a un biais (dépendance ou p plus grand) ».

$\text{p-value} = P(\text{au moins 4 rouges de suite} \mid H_0) = 10^{-4}$.

$10^{-4} < 0,05$, donc on **rejette** H_0 .

Le test d'hypothèse, c'est partout. Le même squelette « hypothèse de référence $\rightarrow$ statistique $\rightarrow$ p-valeur $\rightarrow$ décision » se retrouve dans une foule de domaines très différents. Pour chacun des contextes ci-dessous, à toi de proposer l'hypothèse H_0 .

Exemple 1 — Médecine. On veut tester un nouveau traitement contre l'hypertension. On recrute deux groupes de 200 patients : l'un reçoit le médicament, l'autre un placebo. Au bout de 3 mois, la baisse moyenne de tension est de 9 mmHg dans le premier groupe contre 7 mmHg dans le second. Cette différence est-elle réelle, ou s'explique-t-elle par le simple hasard de l'échantillonnage ?

H_0 : « le traitement n'a aucun effet », soit $\mu_{\text{traitement}} = \mu_{\text{placebo}}$. La différence de 2 mmHg n'est qu'une fluctuation due aux échantillons.

Exemple 2 — Contrôle qualité. Une chaîne de production garantit au plus 1 % de boulons défectueux. Un client effectue une réception : il prélève 500 boulons et en trouve 11 défectueux (2,2 %). Le lot doit-il être refusé ?

H_0 : « la chaîne respecte sa spécification », soit $p_{\text{défaut}} \leq 0,01$. Le test met à l'épreuve l'hypothèse que la fréquence observée (2,2 %) est compatible avec un vrai p inférieur à 1 %.

Exemple 3 — A/B testing. Le service marketing d'un site marchand teste deux versions de la page d'accueil. La version A est montrée à 10 000 visiteurs (320 achats), la version B à 10 000 autres (360 achats). Faut-il déployer la version B partout ?

H_0 : « les deux versions ont le même taux de conversion », soit $p_A = p_B$. La différence observée (3,2 % vs 3,6 %) pourrait n'être qu'un effet du hasard.

Exemple 4 — Sondage électoral. À 48 % d'intentions de vote sur un échantillon de 1000 personnes, le candidat peut-il être assuré qu'il franchira la barre des 50 % au second tour ?

H_0 : « le candidat est sous la barre », soit $p \leq 0,50$. Tant qu'on ne rejette pas H_0 , on ne peut pas conclure qu'il est majoritaire dans la population.

Exemple 5 — Détection de fraude. Dans une comptabilité « naturelle », le *premier chiffre* d'un montant suit la **loi de Benford** ($1 \rightarrow 30\%$, $2 \rightarrow 18\%$, ..., $9 \rightarrow 4,5\%$). Un enquêteur compare la distribution des premiers chiffres d'une déclaration suspecte à cette loi.

H_0 : « les premiers chiffres suivent la loi de Benford » (donc pas de manipulation). Un écart « trop grand » fait rejeter l'hypothèse, et plaide pour des chiffres fabriqués (les humains tirent uniformément quand ils inventent).

Quelques seuils α « publics ». Le seuil dépend des conséquences d'une fausse découverte :

- **Sciences sociales, médecine usuelle** : $\alpha = 5\%$ (par convention).
- **Essais cliniques de phase III (FDA, EMA)** : typiquement $\alpha = 5\%$, mais on demande *deux études indépendantes positives* avant de mettre un médicament sur le marché.
- **Études génomiques (GWAS)** : $\alpha \approx 5 \cdot 10^{-8}$, pour corriger les $\sim 10^6$ tests menés simultanément sur le génome.
- **Physique des particules (CERN)** : pour annoncer une « découverte » (boson de Higgs, 2012),

il faut 5σ , soit $p\text{-value} < 3 \cdot 10^{-7}$.

Plus l'enjeu est lourd (autoriser un médicament, annoncer une particule fondamentale), plus le seuil est sévère.

Attention au p -hacking. Pour que la p -value ait du sens, le seuil α et la statistique de test doivent être fixés **avant** de regarder les données. Sinon, on tombe dans des pratiques qui fabriquent artificiellement des résultats « significatifs » :

- **Tester 20 hypothèses, garder celle qui marche.** Au seuil 5 %, on s'attend à 1 résultat « positif » par pur hasard sur 20, même quand tout est faux.
- **Stopper la collecte dès que $p < 0,05$.** En continuant à observer juste assez, on finit toujours par franchir le seuil.
- **Découper en sous-groupes après coup.** « Le médicament ne marche pas en moyenne, mais marche *chez les femmes de plus de 50 ans* » : avec assez de découpages, une catégorie sera « positive » par hasard.

C'est l'une des causes de la *crise de reproductibilité* en sciences (beaucoup de résultats publiés ne se confirment pas en répétant l'expérience).

3. Test sur une moyenne

On revient sur l'exemple central du CM4 : une usine remplit des sacs de ciment de poids nominal 25 kg, avec un écart-type de remplissage $\sigma = 0,5$ kg *connu*. Le chef de production veut savoir si la machine est **dérégulée**.

Il pèse $n = 100$ sacs et obtient une moyenne empirique $\bar{X}_n = 24,8$ kg.

Question 1. Quelles sont H_0 et H_1 dans ce problème ?

$H_0 : \mu = 25$ (la machine est bien réglée).

$H_1 : \mu \neq 25$ (la machine est dérégulée).

Question 2. En utilisant le TCL, construire une **statistique de test** Z qui suit $\mathcal{N}(0, 1)$ sous H_0 . Calculer la valeur observée Z_{obs} .

Sous H_0 , les sacs sont i.i.d. d'espérance 25 et d'écart-type 0,5. Par le TCL,

$$\bar{X}_n \approx \mathcal{N}\left(25, \frac{0,5^2}{100}\right).$$

On standardise pour obtenir une loi $\mathcal{N}(0, 1)$:

$$Z = \frac{\bar{X}_n - 25}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1), \quad Z_{\text{obs}} = \frac{24,8 - 25}{0,5/\sqrt{100}} = \frac{-0,2}{0,05} = -4.$$


Question 3. Quelle est la p -value ? Conclure au seuil $\alpha = 5\%$.

La machine peut se dérégler vers le haut ou vers le bas : on s'intéresse à l'écart *dans les deux sens*.

$$\text{p-value} = P(|Z| \geq |Z_{\text{obs}}| \mid H_0) = P(|Z| \geq 4) = 2(1 - \Phi(4)).$$

Or $1 - \Phi(4) \approx 3,2 \cdot 10^{-5}$, donc $\text{p-value} \approx 6,4 \cdot 10^{-5}$.

$6,4 \cdot 10^{-5} \ll 0,05$: on **rejette** H_0 . La machine est dérégulée.



Recette du test sur une moyenne (σ connu).

1. $H_0 : \mu = \mu_0$ contre $H_1 : \mu \neq \mu_0$.
2. Statistique : $Z = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$, qui suit $\mathcal{N}(0, 1)$ sous H_0 .
3. Seuil α (souvent 0,05) $\Rightarrow$ valeur critique t_α (par exemple $t_{0,05} = 1,96$).
4. **Décision** : **rejeter** H_0 si $|Z_{\text{obs}}| > t_\alpha$, sinon **ne pas rejeter**.

3.1. Exercice : ce dé est-il pipé ? (test du χ^2)

Au-delà de la moyenne. Le test précédent compare une moyenne empirique à une valeur attendue. On veut souvent tester quelque chose de plus riche : « les fréquences observées d'un phénomène réparti en plusieurs catégories sont-elles compatibles avec celles attendues sous un modèle de référence ? » C'est le rôle du **test du khi-deux d'adéquation** (Karl Pearson, 1900).


Quelques applications classiques.

- **Adéquation à une loi de référence** : un dé est-il équilibré ? les premiers chiffres d'une comptabilité suivent-ils la loi de Benford ?
- **Indépendance entre deux variables qualitatives** : la couleur des yeux dépend-elle du sexe ? le secteur d'activité dépend-il de la région ?
- **Homogénéité entre populations** : la répartition des opinions est-elle la même chez les ≤ 30 ans et les ≥ 60 ans ?

La loi du khi-deux $\chi^2(k)$. Si $U_1, \dots, U_k$ sont k variables *indépendantes* de loi $\mathcal{N}(0, 1)$, alors par définition

$$U_1^2 + U_2^2 + \dots + U_k^2 \sim \chi^2(k).$$

On l'appelle « loi du khi-deux à k degrés de liberté ». Elle ne prend que des valeurs positives, son espérance vaut k , son écart-type $\sqrt{2k}$. Plus la valeur observée s'éloigne de k vers la droite, plus elle est *suspecte*.



Statistique du test d'adéquation. On dispose d'un échantillon de taille n réparti en r catégories d'effectifs observés $O_1, \dots, O_r$. Sous H_0 (« les données suivent telle loi de référence »), on calcule les effectifs *attendus* $E_1, \dots, E_r$, puis

$$\chi_{\text{obs}}^2 = \sum_{i=1}^r \frac{(O_i - E_i)^2}{E_i}.$$

On admet (théorème de Pearson) que sous H_0 et pour n grand, χ_{obs}^2 suit approximativement une loi $\chi^2(r-1)$. La p-value est $P(\chi^2(r-1) \geq \chi_{\text{obs}}^2)$: on rejette si elle est petite, c'est-à-dire si l'écart entre observé et attendu est *trop grand* pour être imputé au hasard.

Énoncé. Un joueur soupçonne son dé à 6 faces d'être pipé. Il le lance $n = 600$ fois et observe :

Face i	1	2	3	4	5	6
Effectif observé O_i	75	90	100	110	100	125

Question 1. Quelles sont H_0 et H_1 ? Sous H_0 , donner les effectifs attendus E_i pour chaque face.

H_0 : « le dé est équilibré », c'est-à-dire $P(\text{face } i) = \frac{1}{6}$ pour tout i .

H_1 : « le dé est pipé » (au moins une face n'a pas la probabilité $\frac{1}{6}$).

Sous H_0 , chaque face est attendue $E_i = n \times \frac{1}{6} = \frac{600}{6} = 100$ fois.

Question 2. Calculer la statistique χ_{obs}^2 .

$$\begin{aligned} \chi_{\text{obs}}^2 &= \frac{(75 - 100)^2}{100} + \frac{(90 - 100)^2}{100} + \frac{(100 - 100)^2}{100} \\ &\quad + \frac{(110 - 100)^2}{100} + \frac{(100 - 100)^2}{100} + \frac{(125 - 100)^2}{100} \\ &= \frac{625 + 100 + 0 + 100 + 0 + 625}{100} = \frac{1450}{100} = 14,5. \end{aligned}$$

Question 3. Quel est le nombre de degrés de liberté ? Comparer χ_{obs}^2 à l'espérance d'une loi $\chi^2(k)$ sous H_0 . Cela paraît-il « normal » ou « suspect » ?

Il y a $r = 6$ catégories, donc $r - 1 = 5$ degrés de liberté. Sous H_0 , χ_{obs}^2 suit approximativement $\chi^2(5)$, d'espérance 5 et d'écart-type $\sqrt{10} \approx 3,16$. Or on observe 14,5, soit environ 3 écarts-types au-dessus de la moyenne attendue : c'est **très suspect**.

Question 4. À l'aide de l'extrait de table de la fonction de répartition de $\chi^2(5)$ ci-dessous, en déduire la p-value, puis conclure aux seuils $\alpha = 5\%$ et $\alpha = 1\%$.

x	9	10	11	12	13	14	14,5	15	16
$F(x) = P(\chi^2(5) \leq x)$	0,891	0,925	0,949	0,965	0,977	0,984	0,987	0,990	0,993

La p-value est la probabilité d'observer un χ^2 *au moins aussi grand* que 14,5 sous H_0 :

$$\text{p-value} = P(\chi^2(5) \geq 14,5) = 1 - F(14,5) = 1 - 0,987 = 0,013.$$

- Au seuil $\alpha = 5\%$: $0,013 < 0,05$, on **rejette** H_0 . Le dé semble pipé.
- Au seuil $\alpha = 1\%$: $0,013 > 0,01$, on **ne rejette pas** H_0 : les données sont à la limite, on ne peut pas conclure formellement à 1% .

La conclusion dépend du seuil choisi — ce qui rappelle l'importance de fixer α *avant* l'expérience.

Pour aller plus loin. Le test du χ^2 s'étend (avec quelques modifications) à de nombreux contextes : indépendance entre deux variables (tableau de contingence), homogénéité entre populations, qualité d'ajustement à une loi continue (après regroupement en classes). On pourra y revenir en TD.

4. Dualité intervalle de confiance $\Longleftrightarrow$ test

Question 1. Au CM4, on avait construit l'intervalle de confiance à 95% pour μ dans le problème des sacs de ciment : $IC_{95\%} = [24,702 ; 24,898]$. Cet intervalle contient-il $\mu_0 = 25$?

Non. La valeur 25 est en dehors. C'est exactement la même conclusion que le test : la machine est déréglée.

Question 2. Montrer que les deux énoncés suivants sont **équivalents** :

- On rejette $H_0 : \mu = \mu_0$ au seuil α .
- $\mu_0 \notin IC_{1-\alpha}$ (l'intervalle de confiance à $1 - \alpha$).

$$\text{On a rejet} \Leftrightarrow |Z_{\text{obs}}| > t_\alpha \Leftrightarrow |\bar{X}_n - \mu_0| > t_\alpha \frac{\sigma}{\sqrt{n}} \Leftrightarrow \mu_0 \notin \left[\bar{X}_n - t_\alpha \frac{\sigma}{\sqrt{n}} ; \bar{X}_n + t_\alpha \frac{\sigma}{\sqrt{n}} \right] \Leftrightarrow \mu_0 \notin IC_{1-\alpha}.$$

C'est exactement le même calcul, vu sous deux angles.

Dualité IC / test. Au même seuil α :

$$\boxed{\text{Rejeter } H_0 : \mu = \mu_0 \Longleftrightarrow \mu_0 \notin IC_{1-\alpha}.$$

L'intervalle de confiance est l'**ensemble des valeurs μ_0 qu'on ne rejeterait pas** au seuil α .

Conséquence pratique. Si on a déjà calculé un IC à 95% , on a *gratuitement* un test bilatéral au seuil 5% pour n'importe quelle valeur μ_0 .

5. Tests bilatéral et unilatéral

5.1. Définition : trois façons de formuler H_0

Jusqu'ici, on a posé $H_0 : \mu = \mu_0$ contre $H_1 : \mu \neq \mu_0$: *n'importe quel* écart à μ_0 amène à rejeter. Mais selon la question pratique qu'on se pose, on peut vouloir **cibler le sens de l'écart** qu'on cherche à détecter. L'hypothèse H_0 (et son alternative H_1) peut alors prendre trois formes :

- **Test bilatéral** : $H_0 : \mu = \mu_0$ contre $H_1 : \mu \neq \mu_0$.
On suspecte un écart *dans n'importe quel sens*.
- **Test unilatéral à gauche** : $H_0 : \mu \geq \mu_0$ contre $H_1 : \mu < \mu_0$.
On veut seulement détecter un écart *vers le bas* : H_0 couvre toutes les valeurs « acceptables » (μ_0 et au-dessus).
- **Test unilatéral à droite** : $H_0 : \mu \leq \mu_0$ contre $H_1 : \mu > \mu_0$.
On veut seulement détecter un écart *vers le haut*.

Remarque. Pour les calculs, le cas « pire » (le plus défavorable au rejet) sous une H_0 unilatérale est toujours $\mu = \mu_0$ (la frontière). On garde donc la même statistique $Z = (\bar{X}_n - \mu_0)/(\sigma/\sqrt{n}) \approx \mathcal{N}(0, 1)$: seule la zone de rejet change.


Le contexte dicte le choix. Le sens de H_0 se déduit *toujours* de la situation à analyser, jamais des données observées. Trois exemples :

- **Sacs de ciment (CM4).** La machine peut se dérégler *vers le haut* (perte de matière première) ou *vers le bas* (sacs sous-remplis, fraude). On veut détecter *tout* dérèglement : $H_0 : \mu = 25$. **Bilatéral.**
- **Ampoules du vendeur (CM4).** Le vendeur annonce $\mu_0 = 1000$ h. Si la durée réelle est *supérieure*, c'est tout bénéfique pour l'acheteur, qui n'a aucune raison de se plaindre : cette situation reste compatible avec H_0 . On veut seulement attraper le dérapage *vers le bas* : $H_0 : \mu \geq 1000$. **Unilatéral à gauche.**
- **Nouveau béton.** Un industriel propose un béton qu'il prétend *plus résistant* que le standard à $\mu_0 = 30$ MPa. Le client cherche à valider que le nouveau produit est vraiment meilleur : $H_0 : \mu \leq 30$. **Unilatéral à droite.**

Important. Le choix « bilatéral / unilatéral » se fait **avant** de regarder les données, jamais pour faire arranger la p-value.

5.2. Conséquence sur la zone de rejet et la p-value

L'idée est la même dans les trois cas : on rejette H_0 si Z_{obs} tombe « loin » dans le(s) sens prévu(s) par H_1 . La différence est où l'on place les α % de probabilité « extrême » sous H_0 :



À retenir — valeurs critiques au seuil $\alpha = 5\%$.

- **Bilatéral** ($H_0 : \mu = \mu_0$) : α se répartit en deux moitiés.
Rejet si $|Z_{\text{obs}}| > 1,96$. p-value = $2(1 - \Phi(|Z_{\text{obs}}|))$.
- **Unilatéral à gauche** ($H_0 : \mu \geq \mu_0$) : tout α dans la queue de gauche.
Rejet si $Z_{\text{obs}} < -1,645$. p-value = $\Phi(Z_{\text{obs}})$.
- **Unilatéral à droite** ($H_0 : \mu \leq \mu_0$) : tout α dans la queue de droite.
Rejet si $Z_{\text{obs}} > 1,645$. p-value = $1 - \Phi(Z_{\text{obs}})$.

Question 1 (revisite des ampoules, CM4). Au CM4, on avait $n = 50$, $\sigma = 100$, $\bar{X}_n = 950$, soit $Z_{\text{obs}} = (950 - 1000)/(100/\sqrt{50}) = -3,53$. Justifier le choix d'un test *unilatéral à gauche*, calculer la p-value associée, et conclure.

Le vendeur tire avantage d'une durée *annoncée trop longue* : on ne s'inquiète que du sens « durent moins », soit $H_0 : \mu \geq 1000$.

$$\text{p-value} = \Phi(-3,53) \approx 2,1 \cdot 10^{-4}.$$

$2,1 \cdot 10^{-4} \ll 0,05$: on **rejette** H_0 . Le vendeur ment.

Question 2. Si on avait choisi (à tort) un test bilatéral, quelle aurait été la p-value ?

$$\text{p-value}_{\text{bilat}} = 2 \cdot \Phi(-3,53) \approx 4,2 \cdot 10^{-4}.$$

Deux fois plus grande, mais on rejette toujours. C'est une règle générale : en passant de bilatéral à unilatéral (du bon côté), la p-value est divisée par deux.

5.3. Application : durée de vie d'une élingue de levage

Un mot sur la loi exponentielle. Pour modéliser une « durée de vie » (durée avant panne d'un composant, durée d'un appel, intervalle entre deux clients dans une file d'attente), on utilise très souvent la **loi exponentielle** $\mathcal{E}(\lambda)$, de densité $f(x) = \lambda e^{-\lambda x}$ pour $x \geq 0$. Ses caractéristiques :

- $\mathbb{E}(X) = 1/\lambda$ et $\text{Var}(X) = 1/\lambda^2$, donc $\sigma = \mu = 1/\lambda$: l'écart-type est égal à la moyenne. C'est très pratique pour les tests : connaître μ suffit à connaître σ .
- **Propriété sans mémoire** : $P(X > s + t \mid X > s) = P(X > t)$. Le composant « oublie » son passé : qu'il ait déjà fonctionné 1 h ou 1000 h, sa durée de vie résiduelle a la même loi.
- Probabilité de survie : $P(X > t) = e^{-\lambda t}$.

Cadre. Une entreprise de BTP commande des **élingues d'acier** pour ses chantiers de levage. Le fabricant annonce une durée de vie moyenne avant rupture de $\mu_0 = 5000$ heures de service. On modélise la durée de vie d'une élingue par une loi $\mathcal{E}(\lambda)$.

Sur un échantillon de $n = 50$ élingues testées jusqu'à la rupture, on observe une durée moyenne empirique $\bar{X}_n = 4200$ heures.

Question 1. Justifier que le test à mener est *unilatéral* et formuler H_0 et H_1 .

Le fabricant aurait intérêt à *surestimer* la durée de vie (argument commercial). Du côté du client, on ne s'inquiète que du dérapage vers le bas :

$$H_0 : \mu \geq 5000 \quad \text{contre} \quad H_1 : \mu < 5000.$$

Unilatéral à gauche.

Question 2. En utilisant le TCL et la propriété $\sigma = \mu$ de la loi exponentielle, construire la statistique de test et calculer Z_{obs} .

Sous H_0 , $\mu = 5000$ donc $\sigma = 5000$. Par le TCL :

$$\bar{X}_n \approx \mathcal{N}\left(5000, \frac{5000^2}{50}\right), \quad Z = \frac{\bar{X}_n - 5000}{5000/\sqrt{50}} \approx \mathcal{N}(0, 1).$$

$$Z_{\text{obs}} = \frac{4200 - 5000}{5000/\sqrt{50}} = \frac{-800}{707,1} \approx -1,13.$$

Question 3. Calculer la p-value et conclure au seuil 5 %.

Test unilatéral à gauche :

$$\text{p-value} = P(Z \leq -1,13 \mid H_0) = \Phi(-1,13) = 1 - \Phi(1,13) \approx 0,129.$$

$0,129 > 0,05$: on **ne rejette pas** H_0 . L'écart de 800 h observé est compatible avec une simple fluctuation d'échantillonnage.

Moralité — attention au piège. « Ne pas rejeter H_0 » ne veut pas dire « prouver que H_0 est vraie ». Cela veut dire : « les données ne suffisent pas à prouver le contraire ». Pour trancher, soit on augmente la taille de l'échantillon, soit on accepte de rester sur l'annonce du fabricant par défaut. Si l'enjeu de sécurité est lourd (rupture d'une élingue $\implies$ chute de charge), on peut préférer un seuil α *plus grand* (10 % par exemple) pour rejeter plus facilement.

6. Deux types d'erreurs

Un test n'est **jamais** certain : il peut se tromper de deux façons.

	H_0 vraie en réalité	H_0 fausse en réalité
Décision : <i>garder</i> H_0	✓ bonne décision	erreur de type II (β)
Décision : <i>rejeter</i> H_0	erreur de type I (α)	✓ bonne décision

- **Erreur de type I** : on rejette H_0 alors qu'elle est vraie. Sa probabilité est précisément α (le seuil qu'on fixe).
- **Erreur de type II** : on garde H_0 alors qu'elle est fausse. Sa probabilité β dépend de la vraie valeur du paramètre (et n'est en général pas égale à $1 - \alpha$).

Le compromis fondamental.

À n fixé : diminuer $\alpha \implies$ augmenter β . Diminuer les deux à la fois nécessite d'augmenter n .

Analogie au tribunal. H_0 = « l'accusé est innocent ».

— Type I : condamner un innocent. Très grave $\implies$ on prend α *petit*.

— Type II : acquitter un coupable. Moins grave dans la philosophie du droit, mais pas négligeable.

Question — Application industrielle. Une machine produit en moyenne 3 % de boulons défectueux. On prélève chaque jour $n = 200$ boulons. On décide la règle « **rejeter le lot et arrêter la machine si plus de 10 défectueux** ».

1. Sous H_0 (la machine est bien réglée, $p = 0,03$), quelle loi suit le nombre X de défauts dans l'échantillon ? Donner son espérance et son écart-type.
2. Par approximation normale (TCL), calculer le risque de type I, c'est-à-dire la probabilité d'arrêter la machine alors qu'elle est bien réglée.

1. $X \sim \mathcal{B}(200, 0,03)$, donc

$$\mathbb{E}(X) = np = 6, \quad \sigma(X) = \sqrt{np(1-p)} = \sqrt{200 \cdot 0,03 \cdot 0,97} \approx 2,41.$$

2. Par le TCL, sous H_0 , $X \approx \mathcal{N}(6, 2,41^2)$.

$$P(X > 10 \mid H_0) = P\left(Z > \frac{10-6}{2,41}\right) = P(Z > 1,66) \approx 1 - \Phi(1,66) \approx 0,049.$$

Soit environ 5 % : c'est notre seuil α . Une fois tous les vingt jours environ, on arrêtera la machine à tort.

Et si on durcissait la règle ? Avec « rejet si plus de 14 défauts », α tomberait à environ 0,05 %... mais on laisserait passer beaucoup plus de lots vraiment défectueux (β augmente). C'est le compromis.

7. Bilan

À retenir.

1. **Test d'hypothèse** : on confronte une hypothèse H_0 (modèle de référence) aux données. On rejette H_0 si l'observation est « trop improbable » sous H_0 .
2. **p-value** : $P(\text{observation au moins aussi extrême} \mid H_0)$. On rejette si $p\text{-value} < \alpha$.
3. **Recette d'un test sur la moyenne (σ connu)** : statistique $Z = (\bar{X}_n - \mu_0)/(\sigma/\sqrt{n})$, qui suit $\mathcal{N}(0, 1)$ sous H_0 . Rejet bilatéral si $|Z_{\text{obs}}| > t_\alpha$ ($t_{0,05} = 1,96$) ; rejet unilatéral si Z_{obs} franchit $\pm u_\alpha$ ($u_{0,05} = 1,645$).
4. **Test du khi-deux d'adéquation** : $\chi^2_{\text{obs}} = \sum (O_i - E_i)^2 / E_i$, distribué $\chi^2(r-1)$ sous H_0 . Rejet si χ^2_{obs} « trop grand ».
5. **Dualité IC $\Leftrightarrow$ test** : on rejette $H_0 : \mu = \mu_0$ au seuil α si et seulement si $\mu_0 \notin IC_{1-\alpha}$.
6. **Bilatéral vs unilatéral** : choisir d'après le contexte, *avant* l'expérience.
7. **Deux types d'erreurs** : type I (α , fixé) et type II (β , dépend de la vraie valeur). Pour diminuer les deux à la fois : augmenter n .